빅데이터·AI

차례

항목을 누르면 해당 장으로 이동합니다. PDF 책갈피에서도 과목을 찾을 수 있습니다.

빅데이터·AI · 30분 학습 방법 6

빅데이터·AI 001회차 | 09-01 원리 I 7

빅데이터·AI 002회차 | 09-01 원리II 8

빅데이터·AI 003회차 | 09-01 예제·적용 9

빅데이터·AI 004회차 | 09-01 직접 문제 10

빅데이터·AI 005회차 | 09-01 해설·재현 12

빅데이터·AI 006회차 | 09-01 원리 I 13

빅데이터·AI 007회차 | 09-01 원리II 14

빅데이터·AI 008회차 | 09-01 예제·적용 15

빅데이터·AI 009회차 | 09-01 직접 문제 16

빅데이터·AI 010회차 | 09-01 해설·재현 18

빅데이터·AI 011회차 | 09-02 원리 I 20

빅데이터·AI 012회차 | 09-02 원리II 21

빅데이터·AI 013회차 | 09-02 예제·적용 22

빅데이터·AI 014회차 | 09-02 직접 문제 23

빅데이터·AI 015회차 | 09-02 해설·재현 25

빅데이터·AI 016회차 | 09-02 원리 I 26

빅데이터·AI 017회차 | 09-02 원리II 27

빅데이터·AI 018회차 | 09-02 예제·적용 28

빅데이터·AI 019회차 | 09-02 직접 문제 29

빅데이터·AI 020회차 | 09-02 해설·재현 31

빅데이터·AI 021회차 | 09-03 원리 Ⅰ 33

빅데이터·AI 022회차 | 09-03 원리Ⅱ 34

빅데이터·AI 023회차 | 09-03 예제·적용 35

빅데이터·AI 024회차 | 09-03 직접 문제 36

빅데이터·AI 025회차 | 09-03 해설·재현 38

빅데이터·AI 026회차 | 09-03 원리 Ⅰ 39

빅데이터·AI 027회차 | 09-03 원리Ⅱ 40

빅데이터·AI 028회차 | 09-03 예제·적용 41

빅데이터·AI 029회차 | 09-03 직접 문제 42

빅데이터·AI 030회차 | 09-03 해설·재현 44

빅데이터·AI 031회차 | 09-04 원리 Ⅰ 46

빅데이터·AI 032회차 | 09-04 원리Ⅱ 47

빅데이터·AI 033회차 | 09-04 예제·적용 48

빅데이터·AI 034회차 | 09-04 직접 문제 49

빅데이터·AI 035회차 | 09-04 해설·재현 51

빅데이터·AI 036회차 | 09-04 원리 Ⅰ 52

빅데이터·AI 037회차 | 09-04 원리Ⅱ 53

빅데이터·AI 038회차 | 09-04 예제·적용 54

빅데이터·AI 039회차 | 09-04 직접 문제 55

빅데이터·AI 040회차 | 09-04 해설·재현 57

빅데이터·AI 041회차 | 09-05 원리 I 59

빅데이터·AI 042회차 | 09-05 원리II 60

빅데이터·AI 043회차 | 09-05 예제·적용 61

빅데이터·AI 044회차 | 09-05 직접 문제 62

빅데이터·AI 045회차 | 09-05 해설·재현 64

빅데이터·AI 046회차 | 09-05 원리 I 65

빅데이터·AI 047회차 | 09-05 원리II 66

빅데이터·AI 048회차 | 09-05 예제·적용 67

빅데이터·AI 049회차 | 09-05 직접 문제 68

빅데이터·AI 050회차 | 09-05 해설·재현 70

빅데이터·AI 051회차 | 09-06 원리 I 72

빅데이터·AI 052회차 | 09-06 원리II 73

빅데이터·AI 053회차 | 09-06 예제·적용 74

빅데이터·AI 054회차 | 09-06 직접 문제 75

빅데이터·AI 055회차 | 09-06 해설·재현 77

빅데이터·AI 056회차 | 09-06 원리 I 78

빅데이터·AI 057회차 | 09-06 원리II 79

빅데이터·AI 058회차 | 09-06 예제·적용 80

빅데이터·AI 059회차 | 09-06 직접 문제 81

빅데이터·AI 060회차 | 09-06 해설·재현 83

빅데이터·AI 061회차 | 09-07 원리 Ⅰ 85

빅데이터·AI 062회차 | 09-07 원리Ⅱ 86

빅데이터·AI 063회차 | 09-07 예제·적용 87

빅데이터·AI 064회차 | 09-07 직접 문제 88

빅데이터·AI 065회차 | 09-07 해설·재현 90

빅데이터·AI 066회차 | 09-07 원리 Ⅰ 91

빅데이터·AI 067회차 | 09-07 원리Ⅱ 92

빅데이터·AI 068회차 | 09-07 예제·적용 93

빅데이터·AI 069회차 | 09-07 직접 문제 94

빅데이터·AI 070회차 | 09-07 해설·재현 96

빅데이터·AI 071회차 | 09-08 원리 Ⅰ 98

빅데이터·AI 072회차 | 09-08 원리Ⅱ 99

빅데이터·AI 073회차 | 09-08 예제·적용 100

빅데이터·AI 074회차 | 09-08 직접 문제 101

빅데이터·AI 075회차 | 09-08 해설·재현 103

빅데이터·AI 076회차 | 09-08 원리 Ⅰ 104

빅데이터·AI 077회차 | 09-08 원리Ⅱ 105

빅데이터·AI 078회차 | 09-08 예제·적용 106

빅데이터·AI 079회차 | 09-08 직접 문제 107

빅데이터·AI 080회차 | 09-08 해설·재현 109

근거·범위·검증 상태 111

30분 학습 방법

30분 안에서 진행하기

복습 3분 → 학습 25분 → 기록 2분으로 진행합니다. 시간이 끝나면 멈추고, 남은 범위는 다음 학습일에 같은 회차에서 이어갑니다. 한 회차를 하루에 반드시 끝내야 하는 것은 아닙니다.

원리 → 문제 → 분리 해설

각 5회차 묶음에서 앞 3회차는 원리와 예제를 읽고, 4회차는 직접 문제를 풀며, 5회차는 해설을 비교하고 답 없이 다시 풉니다. 완료 기준은 읽은 쪽수보다 용어·조건을 설명하고 풀이를 재현할 수 있는지입니다.

강조와 보완 자료 활용

노란색으로 표시한 핵심 조건을 먼저 확인한 뒤, 예제에서 그 조건이 어떻게 쓰였는지 설명합니다. 책 뒤 112쪽부터는 반례·손풀이·추가 확인 문제가 있습니다. 해당 주제가 어려운 날의 학습 시간 안에 골라 읽습니다. 추가 문제의 해설은 별도 절에 있습니다.

공부 기록은 한 곳에

Obsidian의 「공부기록」에 과목·회차·실제 공부 시간·다음 시작점을 남깁니다. 「하루공부」 템플릿을 같은 기록에 추가해서 사용합니다. PDF의 강조나 필기는 진도 표를 자동으로 변경하지 않습니다.

빅데이터·AI 001회차 | 09-01 원리 I

출제범위와 데이터·통계의 첫걸음 · 과목 1/80회차 · 기록 묶음 01의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

이 교재의 출제범위 표시

IBK 채용 FAQ의 IT 직무수행능력에는 전산학과 빅데이터·시사 등이 명시되어 있다. AI 모델링은 디지털 직무 설명에 따로 명시되어 있으므로 IT와 디지털의 범위를 같다고 보지 않는다. 이 교재의 빅데이터 처리·분석 기초는 IBK IT 준비 영역이고, AI 모델·평가 부분은 빅데이터 이해를 돕는 보강이다. 기보 전산 2026 상세 범위의 여섯 과목에 빅데이터·AI가 별도 과목으로 명시되지는 않았다. 따라서 기보 중심이라면 공통 전산 6과목을 먼저 공부한다.

데이터와 문제 정의

정형 데이터는 일정한 스키마를 갖는 테이블 같은 자료다. 반정형 데이터는 JSON·XML처럼 구조와 태그가 있지만 관계형 테이블과 같은 고정 형태만은 아닌 자료다. 비정형 데이터는 문서·영상·음성 등이다. 이미지 파일에 길이와 포맷이 있다고 이미지 전체가 관계형 정형 데이터가 되는 것은 아니다.

빅데이터의 전통적 3V는 Volume·Velocity·Variety다. 양, 생성·처리 속도, 형태의 다양성을 구별한다. Veracity·Value 등의 확장 관점도 있지만 3V·4V·5V의 구성은 자료와 프레임워크마다 다를 수 있다. 몇 GB 이상이면 무조건 빅데이터라는 보편적 경계는 없다. 지연·비용·확장성 요구에 기존 처리 방식이 적합한지 함께 본다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 002회차 | 09-01 원리ㅍ

출제범위와 데이터·통계의 첫걸음 · 과목 2/80회차 · 기록 묶음 01의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

좋은 분석은 목표와 사용 시점에서 시작한다. "데이터가 많으니 AI"보다 "다음 달 장애 위험이 높은 장비를 미리 확인한다"처럼 예측 대상과 시점을 정의한다. 현재 알려진 불량 여부를 다시 맞히는 것과 미래 불량을 예측하는 것은 다른 문제다. 금융에서도 신청 시점에 알 수 없는 미래 정보는 예측 입력으로 쓸 수 없다.

평균·중앙값·분산

평균은 합을 개수로 나눈 값이다. 중앙값은 정렬한 자료의 가운데 값이다. 이상치가 있으면 두 값이 크게 달라질 수 있다. 모집단 분산은 편차 제곱의 평균, 표본 분산의 대표적인 불편 추정식은 편차 제곱 합을 n-1로 나누는 것이다. 문제에 모집단/표본과 분모가 주어지면 그대로 적용한다. 표준편차는 분산의 제곱근이며 원래 데이터와 같은 단위다.

단계별 숫자 예제

처리시간이 2,4,6초라면 평균은 4초, 중앙값도 4초다. 편차는 -2,0,2, 제곱 합은 8초^2다. 모집단 분산은 8/3초^2, 표본 분산은 8/2=4초^2다. 100초 한 건을 추가하면 평균은 28초이고 중앙값은 (4+6)/2=5초다. 평균 상승만으로 일반 요청이 모두 느려졌다고 해석하지 않는다.

확률과 조건

P(A|B)는 B가 일어났다는 조건 아래 A의 확률이다. P(A와 B)/P(B)로 계산하며 P(B)>0이 필요하다. 독립이면 P(A와 B)=P(A)P(B)다. 독립과 상호배타는 다르다. 동시에 일어날 수 없는 두 사건이 모두 양의 확률이면 일반적으로 독립이 아니다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 003회차 | 09-01 예제·적용

출제범위와 데이터·통계의 첫걸음 · 과목 3/80회차 · 기록 묶음 01의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

검사 샘플 100개 중 불량 20개, 경보 30개, 불량이면서 경보 15개라면 P(불량|경보)=15/30=50%, P(경보|불량)=15/20=75%다. 조건의 분모를 바꾸면 답이 달라진다. 이 구분은 나중의 정밀도·재현율과 이어진다.

자가 연습과 풀이

지점별 거래 건수와 평균 거래액을 알고 전체 평균을 계산하려면 지점 평균을 단순 평균하지 말고 거래 건수를 가중치로 사용한다. 거래 2건 평균 100, 8건 평균 200이면 전체 평균은 (2×100+8×200)/10=180이다.

완료 기준

IT·디지털·기보의 범위 구분을 설명하고, 데이터 형태·3V·평균/중앙값·모집단/표본 분산·조건부확률을 직접 계산할 수 있어야 한다.

응용 계산: 낮은 발생률과 조건부확률

거래 10,000건 중 실제 위험 100건, 탐지 재현율 90%, 정상 거래의 오탐률 5%라는 가상 조건을 보자. TP=90,FN=10이다. 정상 9,900건의 5%는 FP=495, 나머지는 TN=9,405다. 경보 585건 중 실제 위험은 90건이므로 정밀도는90/585 약 15.38%다.

재현율 90%를 '경보의 90%가 실제 위험'으로 읽으면 조건부확률을 뒤집은 것이다. 발생률이 낮은 자료에서는 오탐률이 작아 보여도 오탐 건수가 클 수 있다. 좋은 보안·금융 분석은 기준 집단과 분모를 먼저 고정한다. 이 계산은 가상 가정이며 실제 기관의 탐지 성능을 주장하지 않는다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 004회차 | 09-01 직접 문제

출제범위와 데이터·통계의 첫걸음 · 과목 4/80회차 · 기록 묶음 01의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q01

이번 교재에서 공식 출제영역을 구분한 설명으로 옳은 것은?

1. 기보 전산 6과목에 AI 모델링이 별도 명시된다.

2. IBK IT와 디지털 범위는 공식적으로 완전히 같다고 단정한다.

3. IBK IT에는 빅데이터가 명시되고 AI 모델링은 디지털 직무에 명시되므로 두 직무를 같다고 보지 않는다.

4. 빅데이터는 DB 자료가 1GB를 넘을 때만 정의된다.

내 선택·근거: _____

B09Q02

자료 2,4,6의 평균과 모집단 분산은?

1. 4와 4

2. 3과 8

3. 4와 8/3

4. 6과 2

내 선택·근거: _____

B09Q03

불량 20개,경보 30개,불량이면서 경보 15개일 때 P(불량|경보)는?

1. 50%

2. 15%

3. 75%

4. 20%

내 선택·근거: _____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 005회차 | 09-01 해설·재현

출제범위와 데이터·통계의 첫걸음 · 과목 5/80회차 · 기록 묶음 01의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

먼저 직접 푼 뒤 확인합니다.

B09Q01

정답: 3번

FAQ는 IT와 디지털을 나누어 안내한다. 기보의 6과목에는 빅데이터·AI가 별도 명시되지 않으며 보편적인 1GB 경계도 없다.

B09Q02

정답: 3번

평균 4,편차 제곱 합 8,모집단 분산 8/3이다. 표본 분산의 n-1 분모를 쓰면 4지만 문제는 모집단을 지정했다.

B09Q03

정답: 1번

조건이 경보이므로 분모는 경보 30개다. 15/30=50%,15/20=75%는 반대 조건인 P(경보|불량)이다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 006회차 | 09-01 원리 I

출제범위와 데이터·통계의 첫걸음 · 과목 6/80회차 · 기록 묶음 02의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

강화 손풀이: 분모가 다르면 전체 비율의 순위도 달라진다

다음은 가상 업무처리 결과다. 쉬운 건과 어려운 건은 서로 겹치지 않으며 모든 건은 둘 중 하나다.

팀	쉬운 건 성공/전체	어려운 건 성공/전체
A	90/100	1/10
B	19/20	80/100

1단계 - 같은 난이도끼리 비교한다. 쉬운 건은 A 90%, B 95%이고 어려운 건은 A 10%, B 80%다. 각 난이도에서는 B의 관측 성공률이 높다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 007회차 | 09-01 원리ㅍ

출제범위와 데이터·통계의 첫걸음 · 과목 7/80회차 · 기록 묶음 02의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

2단계 - 팀 전체의 실제 분모를 사용한다. A는 91/110 약 82.73%, B는 99/120 = 82.5%다. 전체 비율에서는 A가 약간 높다. A는 쉬운 건의 비중이 100/110으로 크고 B는 어려운 건의 비중이 100/120으로 크기 때문이다. 두 비율을 단순히 더해서 2로 나누면 실제 전체 건의 성공률이 아니다.

3단계 - 비교 목적을 적는다. 실제 처리된 전체 건의 성공률을 보고하는 것과, 두 팀이 같은 난이도 구성을 처리한다고 가정해 비교하는 것은 서로 다른 질문이다. 난이도별 비중을 공통으로 고정하는 비교에서는 공통 비중을 명시해야 한다. 이 표만으로 팀 배치의 인과효과나 미래 성과를 확정할 수 없다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 008회차 | 09-01 예제·적용

출제범위와 데이터·통계의 첫걸음 · 과목 8/80회차 · 기록 묶음 02의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

반례와 별도 손계산. 자료 [2, 4, 6]은 평균 4이고 제곱편차 합이 8이다. 이 세 값 전체를 모집단으로 보는 분산은 8/3이다. 표본분산의 정의로 계산하면 분모 n-1=2이므로 4다. 공식에 넣기 전에 모집단/표본, 성공 건/전체 건의 분모를 적는 습관이 중요하다.

검사 장비의 월별 불량률에서도 검사 제품 구성과 표본 수가 달라지면 평균 비율이 오해를 만든다. 원자료의 건수와 집단 기준을 함께 남겨야 한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 009회차 | 09-01 직접 문제

출제범위와 데이터·통계의 첫걸음 · 과목 9/80회차 · 기록 묶음 02의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이·서술형 작성
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개와 서술형 1개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q25

심화 표에서 A는 쉬운 건 90/100·어려운 건 1/10, B는 19/20·80/100이다. 실제 전체 처리 건의 성공률 비교로 옳은 것은?

1. A 50%, B 87.5%로 B가 높다.

2. 각 난이도에서 B가 높으므로 전체에서도 B가 반드시 높다.

3. A 약 82.73%, B 82.5%로 A가 조금 높다.

4. 두 팀의 전체 성공률은 모두 90%다.

내 선택·근거: _____

B09Q26

A는 쉬운 건 90/100·어려운 건 1/10, B는 쉬운 건 19/20·어려운 건 80/100이 성공했다. 무작위 배치 등 추가 조건은 주어지지 않았다. 이 관측 표만으로 도출할 수 있는 결론은?

1. 전체 비율을 비교할 때 건수는 필요 없다.

2. 관측 자료에서 각 난이도의 B 성공률은 높지만 팀 배치의 인과효과는 확정할 수 없다.

3. B에 맡기면 모든 개별 건이 반드시 성공한다.

4. 팀 차이만으로 전체 비율 역전의 원인을 모두 확정했다.

내 선택·근거: _____

B09Q27

자료 [2, 4, 6]의 제곱편차 합은 8이다. 모집단분산과 표본분산의 정의를 각각 적용한 값은?

1. 8, 8

2. 0, 0

3. 4, 8/3

4. 8/3, 4

내 선택·근거: _____

W09Q01

A의 쉬운 건 90/100·어려운 건 1/10, B는 19/20·80/100이다. ①난이도별 비율과 전체 비율을 계산하고 ②순위 역전의 이유와 인과 해석의 한계를 설명하라.

조건·원리·중간 과정·결론 순서로 먼저 답안을 작성합니다.

내 답안: _____

_____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 010회차 | 09-01 해설·재현

출제범위와 데이터·통계의 첫걸음 · 과목 10/80회차 · 기록 묶음 02의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

서술형 모범답안과 자가 채점 기준

B09Q25

정답: 3번

정답 근거: A=91/110, B=99/120이다. 팀마다 난이도 구성과 분모가 다르다.

「A 50%, B 87.5%로 B가 높다.」 - 50%와 87.5%는 난이도별 비율을 단순 평균한 값으로 실제 전체 건의 비율이 아니다.

「각 난이도에서 B가 높으므로 전체에서도 B가 반드시 높다.」 - 집단별 분모 비중이 다르면 전체의 순위가 바뀔 수 있으며 이 표가 반례다.

「두 팀의 전체 성공률은 모두 90%다.」 - 90%는 A의 쉬운 건 비율이다. 전체 건이나 B의 비율이 아니다.

B09Q26

정답: 2번

정답 근거: 난이도별 비율 비교는 가능하다. 표는 무작위 배치나 다른 요인의 통제를 보장하지 않으므로 인과효과는 확정하지 않는다.

「B에 맡기면 모든 개별 건이 반드시 성공한다.」 - 95%와 80% 모두 100%가 아니므로 실패 건이 존재한다.

「팀 차이만으로 전체 비율 역전의 원인을 모두 확정했다.」 - 난이도 구성 차이는 표에서 보이지만 다른 인과 요인을 통제한 연구라는 조건은 없다.

「전체 비율을 비교할 때 건수는 필요 없다.」 - 전체 성공률은 성공 건수 합/전체 건수 합으로 계산하므로 분모의 건수가 필요하다.

B09Q27

정답: 4번

정답 근거: 평균 4의 제곱편차 합 8을 모집단은 n=3, 표본은 n-1=2로 나눈다.

「4, 8/3」 - 두 분모의 적용 순서를 바꿨다.

「8, 8」 - 제곱편차 합을 분산으로 오인하고 분모를 생략했다.

「0, 0」 - 평균에 대한 편차의 합은 0이지만 제곱편차 합과 분산은 0이 아니다.

W09Q01

A의 쉬운 건 90/100·어려운 건 1/10, B는 19/20·80/100이다. ①난이도별 비율과 전체 비율을 계산하고 ②순위 역전의 이유와 인과 해석의 한계를 설명하라.

모범답안

쉬운 건은 A 90%·B 95%, 어려운 건은 A 10%·B 80%다. 전체는 A 91/110 약 82.73%, B 99/120=82.5%로 A가 조금 높다. A는 쉬운 건 비중이 크고 B는 어려운 건 비중이 크므로 서로 다른 가중치가 전체 순위를 바꾼다. 표는 관측 비율이며 배치의 무작위성이나 다른 요인 통제가 주어지지 않아 팀 변경의 인과효과를 확정하지 않는다.

10점 자가 채점 기준

- 3점: 네 난이도별 비율을 정확히 계산한다. 네 값 모두 3점, 세 값 2점, 한두 값 1점.
- 3점: 전체 분모 110·120을 사용해 두 비율과 A가 높은 순위를 제시한다. 두 비율 2점, 순위 1점.
- 4점: 서로 다른 난이도 가중치 2점, 인과효과를 확정할 조건이 없다는 한계 2점을 설명한다.

점수는 학습용 자가 채점이며 실제 시험 배점 재현이 아닙니다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 011회차 | 09-02 원리 I

ETL·데이터웨어하우스·OLAP: 분석 자료를 만드는 과정 · 과목 11/80회차 · 기록 묶음 03의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

OLTP와 OLAP

OLTP는 일상적인 거래를 짧고 정확하게 처리하는 목적이 강하다. OLAP는 여러 기간·집단의 데이터를 모아 분석하는 목적이 강하다. 계좌 이체·신청서 저장은 OLTP 사례, 월별·지역별 신청 건수 분석은 OLAP 사례다. 이는 사용 목적의 구분이며 모든 제품이 하나의 목적만 지원하는 것은 아니다.

데이터웨어하우스는 분석을 위해 통합·정리한 데이터를 보관한다. 데이터마트는 특정 부서·주제에 맞춘 부분 집합으로 설명할 수 있다. 데이터레이크는 다양한 형태의 원천 자료를 유연하게 보관하는 접근이다. 레이크에 넣었다고 품질·권한·메타데이터가 자동으로 관리되는 것은 아니다. 최근 제품의 융합 이름은 원리와 구별한다.

ETL과 ELT

ETL은 추출→변환→적재, ELT는 추출→적재→변환이라는 순서를 중심으로 구분한다. ETL은 적재 전에 변환을 수행하고 ELT는 적재된 환경의 연산을 활용한다. 어느 방식이 항상 더 좋거나 항상 개인정보에 안전한 것은 아니다. 처리량·환경·비용·접근 통제와 요구를 고려한다.

변환에는 타입 통일, 단위 맞추기, 중복 처리, 키 연결, 결측값 처리, 업무 규칙 검증이 들어간다. 날짜가 문자열인지 시각인지, UTC인지 국내 시각인지 확인하지 않으면 날짜별 집계가 달라질 수 있다. 자료의 원천·수집 시각·변환 규칙을 추적하는 메타데이터와 계보도 관리한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 012회차 | 09-02 원리ㅍ

ETL·데이터웨어하우스·OLAP: 분석 자료를 만드는 과정 · 과목 12/80회차 · 기록 묶음 03의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

차원 모델과 grain

팩트 테이블은 측정값과 차원 키를 담는다. 차원 테이블은 날짜·지역·상품 같은 분석 기준을 담는다. 별 모양 스키마는 팩트가 여러 차원에 직접 연결되는 형태를 설명하고, 눈송이 스키마는 차원을 더 정규화해 나누는 형태를 설명한다. 팩트의 grain은 한 행이 무엇을 의미하는지다. "신청서 한 건"과 "지역·날짜별 합계"를 같은 테이블에서 구분 없이 섞으면 집계가 중복될 수 있다.

가산 가능성도 중요하다. 거래 금액과 건수는 같은 기준에서 합칠 수 있지만 평균·비율은 분모가 필요하다. 재고·잔액 같은 시점 값은 날짜에 걸쳐 무조건 합산하면 의미가 달라진다. 단순 SUM을 적용하기 전에 측정값의 의미를 확인한다.

단계별 사례: 검사 로그에서 보고서 만들기

원천은 event_id, equipment_id, event_time, result, duration_ms다. 먼저 event_id의 중복 수집을 확인한다. 둘째 event_time의 시간대를 통일한다. 셋째 result 코드의 정의를 맞춘다. 넷째 장비·날짜 차원으로 연결하고 "검사 1회=팩트 1행"이라는 grain을 정한다. 다섯째 건수·불량 건수·시간 합계로 집계한다. 불량률은 불량 건수/검사 건수로 계산한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 013회차 | 09-02 예제·적용

ETL·데이터웨어하우스·OLAP: 분석 자료를 만드는 과정 · 과목 13/80회차 · 기록 묶음 03의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

같은 로그를 재처리해도 결과가 중복되지 않도록 event_id 기준의 처리 규칙을 정하면 멱등성 확보에 도움을 준다. 멱등성을 "배치가 한 번만 실행된다"로 이해하면 재시도 때 중복 문제를 놓친다.

숫자 예제: JOIN으로 생긴 중복

신청서 A에 첨부 2개, B에 첨부 3개가 있고 신청서 금액은 각각 100·200이라고 하자. 신청서와 첨부를 조인한 뒤 신청 금액을 단순 합치면 100×2+200×3=800이 된다. 실제 신청서 합계는 300이다. 분석 단위가 늘어나는 조인을 인지하고 먼저 첨부를 신청서 단위로 집계하거나 목적에 맞게 중복을 제거해야 한다.

자가 연습과 풀이

일별 불량률 10%(10/100)와 50%(5/10)의 전체 불량률은 (10+5)/(100+10)=15/110 약 13.64%다. 두 비율의 단순 평균 30%는 전체의 불량률이 아니다. 비율 집계에는 분자와 분모를 함께 보관한다.

완료 기준

OLTP/OLAP·ETL/ELT를 목적과 순서로 설명하고, grain·조인 중복·가중 평균을 점검할 수 있어야 한다. 데이터웨어하우스와 레이크의 이름보다 품질·권한·계보를 묻는 습관을 갖자.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 014회차 | 09-02 직접 문제

ETL·데이터웨어하우스·OLAP: 분석 자료를 만드는 과정 · 과목 14/80회차 · 기록 묶음 03의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q04

ETL과 ELT의 가장 직접적인 구분은?

1. 데이터가 숫자인지 여부

2. 변환과 적재의 순서

3. 반드시 사용하는 운영체제

4. 암호 키 길이

내 선택·근거: _____

B09Q05

신청서 A 금액100·첨부2개,B 금액200·첨부3개를 조인해 행마다 신청 금액을 합쳤다. 실제 합계와 잘못된 합계는?

1. 800과300

2. 300과800

3. 300과500

4. 500과800

내 선택·근거: _____

B09Q06

100건 중 불량10건인 날과10건 중 불량5건인 날의 전체 불량률은?

1. 15/110 약 13.64%

2. 30%

3. 15%

4. 50%

내 선택·근거: _____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 015회차 | 09-02 해설·재현

ETL·데이터웨어하우스·OLAP: 분석 자료를 만드는 과정 · 과목 15/80회차 · 기록 묶음 03의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

먼저 직접 푼 뒤 확인합니다.

B09Q04

정답: 2번

ETL은 추출-변환-적재,ELT는 추출-적재-변환이다. 데이터 타입·운영체제·키 길이는 두 접근의 정의가 아니다.

B09Q05

정답: 2번

실제는100+200=300,조인 후는100×2+200×3=800이다. grain이 바뀌어 같은 신청서 금액이 반복된다.

B09Q06

정답: 1번

분자·분모를 합쳐15/110이다. 일별 비율의 단순 평균30%는 검사 건수를 무시한다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 016회차 | 09-02 원리 I

ETL·데이터웨어하우스·OLAP: 분석 자료를 만드는 과정 · 과목 16/80회차 · 기록 묶음 04의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

응용 문제: 집계 전에 날짜 의미 확인

event_time은 실제 발생 시각,received_time은 시스템 수신 시각이라고 하자. 자정 뒤 늦게 들어온 전날 사건을 수신일로 합치면 발생일 보고서가 달라진다. 어떤 시각을 기준으로 분석하는지, 늦은 자료를 언제 재집계하는지 정해야 한다. 문자열 날짜의 사전순 정렬이 실제 시각순과 같다는 가정도 포맷·시간대가 맞을 때만 가능하다.

자료의 계보는 보고서 값이 어떤 원천과 변환에서 왔는지 설명하는 연결이다. SQL 파일 이름만 저장하고 입력 자료·설정·버전을 남기지 않으면 같은 보고서를 재현하기 어렵다. 분자·분모·필터·grain을 보고서 정의에 함께 기록하자.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 017회차 | 09-02 원리ㅍ

ETL·데이터웨어하우스·OLAP: 분석 자료를 만드는 과정 · 과목 17/80회차 · 기록 묶음 04의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

강화 손풀이: 사실 테이블의 한 건과 이력 차원의 한 행을 구분한다

가상 사실 테이블은 신청 ID당 정확히 한 행이며 A의 금액은 100, B의 금액은 200이다. 고객 차원에는 A의 이전 버전과 새 버전 두 행, B의 한 행이 있다. 금액의 단위는 동일하다.

1단계 - ID만으로 결합한 행을 적는다. A는 차원 두 행과 결합해 100이 두 번 나오고 B는 200이 한 번 나온다. 결합 뒤 SUM은 400이 된다. 원래 신청 금액 총계는 100+200=300이다. 결합 전 원자료가 중복되지 않아도 일대다 결합은 금액을 부풀릴 수 있다.

2단계 - 시간 조건을 추가한다. A의 이전 버전은 [2026-01-01, 2026-09-01), 새 버전은 [2026-09-01, 무한대) 동안 유효하다고 가정한다. 대괄호는 포함, 소괄호는 제외다. 신청 시각이 8월 31일이면 이전 버전, 9월 1일 00:00이면 새 버전과 결합한다. 시작 ≤ 신청 시각 < 종료를 만족하는 행이 하나인지 검증한다. 현재 버전만 고르면 과거 신청의 지역이나 담당 속성이 바뀔 수 있다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 018회차 | 09-02 예제·적용

ETL·데이터웨어하우스·OLAP: 분석 자료를 만드는 과정 · 과목 18/80회차 · 기록 묶음 04의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

3단계 - 정상 조건과 장애 조건을 분리한다. 이력 구간이 겹치면 두 행이 선택될 수 있고 구간에 빈틈이 있으면 차원 행이 없을 수 있다. 각각 오류로 기록하거나 별도로 정한 처리 정책을 적용한다. 이 문제는 시간 조건만 붙이면 자동으로 해결되는 것이 아니다.

반례. SUM(DISTINCT 금액)은 신청 ID 중복을 제거하는 방법이 아니다. 서로 다른 신청 C와 D가 각각 100이면 합계는 200이어야 하는데 DISTINCT 금액은 100만 남긴다. 먼저 집계 단위와 결합의 최대 행 수를 확인하고, 승인된 하나의 차원 행과 연결한 뒤 금액을 집계한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 019회차 | 09-02 직접 문제

ETL·데이터웨어하우스·OLAP: 분석 자료를 만드는 과정 · 과목 19/80회차 · 기록 묶음 04의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이·서술형 작성
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개와 서술형 1개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q28

신청 A 금액 100, B 금액 200의 사실 두 행에 차원 A 두 행·B 한 행을 ID만으로 결합했다. 결합 후 금액 합과 원래 신청 총액은?

1. 400, 300

2. 300, 300

3. 400, 400

4. 200, 300

내 선택·근거: _____

B09Q29

차원 A의 이전 버전은 [2026-01-01, 2026-09-01), 새 버전은 [2026-09-01, 무한대) 유효하다. 2026-09-01 00:00 신청에 맞는 버전은?

1. 이전 버전 하나

2. 두 버전 모두

3. 어느 버전도 아님

4. 새 버전 하나

내 선택·근거: _____

B09Q30

서로 다른 신청 C와 D의 금액이 각각 100이다. ID 기준 중복 결합 문제를 SUM(DISTINCT 금액)으로 해결하려는 설명으로 옳은 것은?

1. 금액을 문자열로 바꾸면 ID 기준 중복 문제가 해결된다.

2. 신청 ID가 다르면 DISTINCT 금액도 반드시 둘을 보존한다.

3. DISTINCT는 차원 이력의 유효 구간을 검증한다.

4. 서로 다른 신청의 같은 금액도 하나로 줄여 100이 되므로 올바른 총액 200을 보장하지 않는다.

내 선택·근거: _____

W09Q02

신청 A 100·B 200의 사실 테이블과 차원 A두 버전·B한 버전이 있다. ①ID만으로 결합한 합계를 구하고 ②이력 구간 [시작,종료)에 따른 결합 조건을 쓰고 ③SUM(DISTINCT 금액)의 반례를 제시하라.

조건·원리·중간 과정·결론 순서로 먼저 답안을 작성합니다.

내 답안: _____

_____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 020회차 | 09-02 해설·재현

ETL·데이터웨어하우스·OLAP: 분석 자료를 만드는 과정 · 과목 20/80회차 · 기록 묶음 04의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

서술형 모범답안과 자가 채점 기준

B09Q28

정답: 1번

정답 근거: 결합 결과는 A100 두 행과 B200 한 행이라 400이다. 원래 두 신청 합계는 300이다.

「300, 300」 - 차원의 A 두 행이 사실 A를 반복시키는 효과를 빠뜨렸다.

「400, 400」 - 결합으로 행이 늘어난 것이 원래 신청 금액까지 늘린 것은 아니다.

「200, 300」 - A 두 행의 200만 세고 B200을 누락했다.

B09Q29

정답: 4번

정답 근거: 새 버전의 시작은 포함하고 이전 버전의 종료는 제외하므로 새 버전만 선택한다.

「이전 버전 하나」 - 이전 구간의 종료 9월 1일은 소괄호로 제외한다.

「두 버전 모두」 - 두 구간이 경계 시각을 동시에 포함하지 않는다.

「어느 버전도 아님」 - 새 버전 시작은 대괄호로 포함한다.

B09Q30

정답: 4번

정답 근거: DISTINCT의 비교 대상은 금액 값이다. C와 D의 같은 100을 하나로 만들므로 합계는 100이 된다.

「신청 ID가 다르면 DISTINCT 금액도 반드시 둘을 보존한다.」 - ID는 DISTINCT 금액의 비교 대상이 아니므로 보존 근거가 없다.

「DISTINCT는 차원 이력의 유효 구간을 검증한다.」 - 집계 함수는 이력 구간의 중첩·공백을 검증하지 않는다.

「금액을 문자열로 바꾸면 ID 기준 중복 문제가 해결된다.」 - 자료형 변경은 결합 행 수나 신청 식별 기준을 바꾸지 않는다.

W09Q02

신청 A 100·B 200의 사실 테이블과 차원 A두 버전·B한 버전이 있다. ①ID만으로 결합한 합계를 구하고 ②이력 구간 [시작,종료)에 따른 결합 조건을 쓰고 ③SUM(DISTINCT 금액)의 반례를 제시하라.

모범답안

ID만으로 결합하면 A 100이 두 번, B 200이 한 번 나와 400이지만 원래 총액은 300이다. ID 일치와 시작≤신청 시각<종료를 함께 적용하고 같은 시각에 선택되는 차원 행이 하나인지 검증한다. 종료와 다음 시작이 같은 경계는 새 버전만 선택한다. 서로 다른 신청 C 100·D 100은 총액 200이지만 DISTINCT 금액은 100만 남기므로 ID 기준 중복 해결을 보장하지 않는다.

10점 자가 채점 기준

- 3점: 결합 행 100·100·200과 합 400을 2점, 원래 합 300을 1점으로 설명한다.
- 4점: ID 일치 1점, 시작 포함·종료 제외 2점, 선택 행 유일성과 구간 중첩/공백 검증 1점을 쓴다.
- 3점: 서로 다른 ID의 같은 금액 반례 1점, 정상 합 200과 DISTINCT 합 100의 비교 2점을 제시한다.

점수는 학습용 자가 채점이며 실제 시험 배점 재현이 아닙니다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 021회차 | 09-03 원리 I

분산 처리·MapReduce·NoSQL: 규모가 커질 때의 선택 · 과목 21/80회차 · 기록 묶음 05의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

수평 확장과 분산의 비용

수직 확장은 한 시스템의 자원을 늘리고, 수평 확장은 여러 노드를 함께 사용하는 방식이다. 분산은 처리량과 저장량을 늘리고 장애 영향을 줄이는 데 도움을 줄 수 있지만 네트워크·조정·재시도·일관성 비용을 추가한다. 데이터가 작고 단일 시스템이 충분하다면 복잡한 분산 구조가 오히려 부담일 수 있다.

파티셔닝은 데이터를 여러 부분으로 나눠 저장·처리한다. 복제는 같은 자료의 사본을 여러 곳에 둔다. 둘은 다르며 함께 사용할 수 있다. 해시 파티셔닝은 키의 해시를 기준으로 나누고, 범위 파티셔닝은 값 범위를 기준으로 나눈다. 인기 키에 자료가 몰리면 데이터 편향으로 일부 노드가 느려질 수 있다.

MapReduce의 흐름

Map은 입력을 중간 키·값으로 변환한다. Shuffle/Group은 같은 키의 값을 모아 Reduce로 보내며, Reduce는 키별로 결과를 계산한다. Combiner는 허용되는 경우 지역 중간 집계를 줄여 전송량을 낮출 수 있지만 모든 연산에 안전하거나 실행이 보장되는 단계로 가정하면 안 된다. 재결합해도 결과가 유지되는 성질을 검토한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 022회차 | 09-03 원리ㅍ

분산 처리·MapReduce·NoSQL: 규모가 커질 때의 선택 · 과목 22/80회차 · 기록 묶음 05의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

단계별 예제: 지점별 신청 건수

원천 행은 부산·부산·수원·부산·수원이라고 하자. Map은 (부산,1),(부산,1),(수원,1),(부산,1),(수원,1)을 만든다. Group은 부산:[1,1,1],수원:[1,1]로 모은다. Reduce에서 합계를 내면 부산 3,수원 2다. 같은 입력에 재시도가 생길 수 있으므로 처리 프레임워크와 출력 저장 방식의 계약을 이해해야 한다.

평균을 Combiner에서 단순 평균값 하나로만 합치면 틀릴 수 있다. 파티션 A의 값 10·20은 평균 15, B의 값 100은 평균 100이다. 두 평균의 평균 57.5는 전체 평균 130/3 약 43.33과 다르다. 지역 합계·개수를 함께 전달하면 (30+100)/(2+1)로 올바르게 재결합할 수 있다.

NoSQL의 종류

키-값 저장소는 키로 값을 찾는 접근, 문서 저장소는 구조 있는 문서 단위의 저장, 넓은 열 계열 저장소는 큰 분산 테이블과 열 계열 구조, 그래프 저장소는 관계와 탐색을 중심으로 설명한다. 제품마다 쿼리·트랜잭션·일관성·인덱스 기능이 다르다. "NoSQL은 SQL을 전혀 지원하지 않는다", "트랜잭션이 무조건 없다"는 일반화는 틀릴 수 있다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

보완 B02 → 114쪽

빅데이터·AI 023회차 | 09-03 예제·적용

분산 처리·MapReduce·NoSQL: 규모가 커질 때의 선택 · 과목 23/80회차 · 기록 묶음 05의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

어떤 DB를 선택할지는 데이터 형태만 아니라 접근 패턴, 거래 정확성, 지연, 운영·복구 비용에 달려 있다. 계좌 이체처럼 원자성과 명확한 일관성이 필요한 거래와 대규모 로그 검색의 요구는 같지 않다.

CAP의 조건

CAP의 설명에서 네트워크 분할이 발생한 상황에 모든 요청의 가용성과 강한 일관성을 동시에 보장하기 어렵다는 제한을 이해한다. 여기서 C는 모든 노드가 임의 순간 완전히 같은 파일을 가진다는 모호한 말이 아니라 일관성 모델의 의미와 연결된다. A도 단순 연간 가동률과 다른 엄밀한 정의를 가진다. "언제나 셋 중 둘을 아무 조건 없이 고른다"는 암기보다 분할이 생겼을 때 어떤 요청을 거부하거나 어떤 읽기를 허용하는지를 생각한다.

자가 연습과 풀이

지점 키로 나눴더니 부산 데이터가 90%이고 나머지가 10%다. 노드가 10대라는 이유만으로 각 노드가 10%씩 처리한다고 볼 수 없다. 키 분포와 파티션 배치를 확인해야 한다. 복제를 늘려 저장 사본이 많아져도 쓰기 조정 비용과 복구 조건이 함께 생긴다.

완료 기준

파티셔닝·복제, Map·Group·Reduce, 합계·개수 기반 평균을 구분하고 NoSQL과 CAP의 과도한 일반화를 고칠 수 있어야 한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 024회차 | 09-03 직접 문제

분산 처리·MapReduce·NoSQL: 규모가 커질 때의 선택 · 과목 24/80회차 · 기록 묶음 05의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q07

파티셔닝과 복제의 설명으로 옳은 것은?

1. 둘 모두 같은 자료의 사본을 늘리는 것

2. 둘 모두 자료를 무조건 삭제하는 것

3. 둘은 절대로 함께 사용할 수 없다.

4. 파티셔닝은 자료 분할,복제는 사본 저장이며 함께 사용할 수 있다.

내 선택·근거: _____

B09Q08

파티션 A값10·20,B값100의 전체 평균을 Combiner로 올바르게 재결합하는 방법은?

1. 지역 평균15와100의 평균57.5

2. 지역 최솟값10과100의 합110

3. 값 개수와 무관하게100만 사용

4. 지역 합계30·100과 개수2·1을 합쳐130/3 계산

내 선택·근거: _____

B09Q09

CAP에 대한 기초 설명으로 가장 정확한 것은?

1. 네트워크 분할 발생 조건에서 모든 요청의 가용성과 강한 일관성을 동시에 보장하기 어렵다는 제한을 다룬다.

2. 모든 시스템은 언제나 무조건 세 항목 중 임의의 두 개만 가진다.

3. 가용성은 반드시 월간 가동률99%라는 뜻이다.

4. NoSQL은 모두 같은 일관성·트랜잭션 기능을 가진다.

내 선택·근거: _____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 025회차 | 09-03 해설·재현

분산 처리·MapReduce·NoSQL: 규모가 커질 때의 선택 · 과목 25/80회차 · 기록 묶음 05의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

먼저 직접 푼 뒤 확인합니다.

B09Q07

정답: 4번

분할과 사본은 다른 목적이다. 분할된 각 부분에 사본을 둘 수도 있어 함께 적용할 수 있다.

B09Q08

정답: 4번

평균은 합계와 개수를 함께 전달해야 올바르게 재결합된다. 파티션 크기가 달라 지역 평균의 단순 평균은 틀린다.

B09Q09

정답: 1번

분할 조건과 정의를 놓치지 않아야 한다. CAP의 엄밀한 가용성·일관성은 단순 가동률·사본 동일성과 다르며 제품 특성도 다양하다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 026회차 | 09-03 원리 I

분산 처리·MapReduce·NoSQL: 규모가 커질 때의 선택 · 과목 26/80회차 · 기록 묶음 06의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

응용 문제: 장애 재시도와 한 번 처리

분산 작업에서 실패한 작업을 다시 실행할 수 있다. 처리 코드가 외부 시스템에 '금액을더한다'라는 부작용을 만들면 재시도 때 중복 반영될 수 있다. 프레임워크가 내부 계산 결과를 관리한다고 외부 거래도 항상 한 번만 실행되는 것은 아니다. 이벤트 식별자와 멱등 처리·트랜잭션 경계를 확인한다.

같은 요청을 여러 번 적용해도 의도한 상태가 같으면 멱등성의 관점으로 설명할 수 있다. '잔액을10증가'와 '이벤트E를미반영이면한번적용'은 조건이 다르다. 로그 분석과 실제 금전 거래의 실패 처리 요구를 똑같이 취급하지 않는다.

강화 손풀이: 분산 평균은 평균끼리 평균 내지 않는다

같은 키에 속하는 정확한 정수 자료를 두 파티션으로 나눴다. P1=[2, 4], P2=[10, 10, 10, 10]이다. 이 예시에서는 오버플로와 부동소수점 반올림을 무시한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 027회차 | 09-03 원리ㅍ

분산 처리·MapReduce·NoSQL: 규모가 커질 때의 선택 · 과목 27/80회차 · 기록 묶음 06의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

1단계 - 잘못된 방법을 먼저 계산한다. P1 평균은 3, P2 평균은 10이다. 평균의 평균은 (3+10)/2=6.5다. 이 계산은 두 파티션의 건수가 같을 때의 가중치만 사용하므로 여기서는 전체 평균이 아니다.

2단계 - 합과 건수를 함께 보낸다. P1은 (6, 2), P2는 (40, 4)를 보낸다. 결합 규칙은 (s1+s2, n1+n2)다. 최종 값은 (46, 6), 평균은 46/6=23/3 약 7.67이다. 빈 파티션은 (0, 0)으로 결합하고, 최종 건수가 0이면 평균을 정의하지 않는 정책을 둔다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 028회차 | 09-03 예제·적용

분산 처리·MapReduce·NoSQL: 규모가 커질 때의 선택 · 과목 28/80회차 · 기록 묶음 06의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

3단계 - 중간 결합 후에도 같은 의미를 유지한다. 합과 건수의 쌍은 어느 순서로 묶어도 정확한 정수 계산에서는 같은 결과를 낸다. 중간 집계의 유무나 여러 번의 재집계에도 원자료의 평균과 같은 결과를 얻도록 설계한다. Hadoop 문서는 combiner를 선택적인 지역 집계로 설명한다. 응용에서는 combiner가 한 번 실행될 것을 전제로 정답을 만들면 안 된다.

병목 반례. 가상 병렬 작업 세 개가 동시에 시작하고 필요한 작업자가 충분하며 공유 자원 경합과 통신 비용이 없다고 하자. 시간은 2초, 2초, 8초다. 전체 완료 시간은 합 12초가 아니라 최댓값 8초다. 작업자 수만 늘려도 이미 시작된 8초 작업이 저절로 빨라지지는 않는다. 키 편중, 파티션 분할 가능성, 집계 의미 보존을 확인한다. 실제 시스템에서는 스케줄링·셔플·재시도 비용도 있어 이 단순 최댓값 모형을 그대로 성능 보장으로 쓰면 안 된다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 029회차 | 09-03 직접 문제

분산 처리·MapReduce·NoSQL: 규모가 커질 때의 선택 · 과목 29/80회차 · 기록 묶음 06의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이·서술형 작성
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개와 서술형 1개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q31

P1=[2,4], P2=[10,10,10,10]의 전체 평균을 분산 집계하려 한다. 적절한 중간 자료와 결과는?

1. 각 파티션 최댓값만 전달해 전체 평균 7을 구한다.

2. (합, 건수)를 결합해 (46,6), 평균 23/3을 구한다.

3. 파티션 개수 2로 전체 합 46을 나눠 23을 구한다.

4. 평균 3과 10을 단순 평균해 6.5를 구한다.

내 선택·근거: _____

B09Q32

정확한 정수 합과 건수 쌍으로 평균을 집계한다. 최종 건수가 0인 상황에 적절한 처리는?

1. 평균을 정의하지 않는 별도 정책을 적용한다.

2. 평균은 언제나 0으로 수학적으로 확정된다.

3. 건수 0을 1로 바꾸면 원자료의 평균과 같다.

4. 다른 키의 평균을 가져오면 같은 키의 정확한 평균이다.

내 선택·근거: _____

B09Q33

가상 작업 세 개가 동시에 시작하며 충분한 작업자·경합과 통신 비용 없음·작업 쪼개기 없음으로 정한다. 시간 2초, 2초, 8초일 때 완료 시간은?

1. 12초

2. 4초

3. 작업자 한 명을 추가하면 반드시 2초

4. 8초

내 선택·근거: _____

W09Q03

P1=[2,4], P2=[10,10,10,10]이다. ①평균의 평균이 잘못되는 수치를 보이고 ②분산 집계의 중간 자료와 결합식을 쓰고 ③최종 0건의 처리 조건을 적어라.

조건·원리·중간 과정·결론 순서로 먼저 답안을 작성합니다.

내 답안: _____

_____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 030회차 | 09-03 해설·재현

분산 처리·MapReduce·NoSQL: 규모가 커질 때의 선택 · 과목 30/80회차 · 기록 묶음 06의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

서술형 모범답안과 자가 채점 기준

B09Q31

정답: 2번

정답 근거: 합 6+40=46, 건수 2+4=6이므로 46/6이다. 다른 크기의 파티션도 바르게 가중한다.

「평균 3과 10을 단순 평균해 6.5를 구한다.」 - 건수 2와 4를 같은 비중으로 취급해 전체 평균을 왜곡한다.

「각 파티션 최댓값만 전달해 전체 평균 7을 구한다.」 - 최댓값 4와 10만으로 원래 여섯 값의 합과 건수를 복구할 수 없다.

「파티션 개수 2로 전체 합 46을 나눠 23을 구한다.」 - 평균의 분모는 관측 건수 6이며 파티션 수 2가 아니다.

B09Q32

정답: 1번

정답 근거: 0건의 평균은 0으로 나눌 수 없으므로 결측·오류 등 명시된 정책을 적용해야 한다.

「평균은 언제나 0으로 수학적으로 확정된다.」 - 합 0이라고 0/0이 0으로 정의되는 것은 아니다.

「건수 0을 1로 바꾸면 원자료의 평균과 같다.」 - 분모를 바꾸는 것은 실제 자료의 산술평균 계산이 아니다.

「다른 키의 평균을 가져오면 같은 키의 정확한 평균이다.」 - 다른 키의 자료는 해당 키의 원자료를 대신하지 못한다.

B09Q33

정답: 4번

정답 근거: 모두 동시에 진행하며 마지막 8초 작업이 끝나야 완료하므로 최댓값 8초다.

「12초」- 12초는 직렬로 세 시간을 더한 값이며 동시 시작 조건과 다르다.

「4초」- 평균 4초는 마지막 작업의 완료 시각이 아니다.

「작업자 한 명을 추가하면 반드시 2초」- 작업을 쪼개지 않으며 이미 충분한 작업자가 있으므로 추가 한 명이 8초 작업 시간을 줄이지 않는다.

W09Q03

P1=[2,4], P2=[10,10,10,10]이다. ①평균의 평균이 잘못되는 수치를 보이고 ②분산 집계의 중간 자료와 결합식을 쓰고 ③최종 0건의 처리 조건을 적어라.

모범답안

파티션 평균은 3·10이고 단순 평균은 6.5지만 전체 평균은 46/6=23/3이다. 중간 자료는 (합,건수)로 P1 (6,2), P2 (40,4)다. 결합식은(s1+s2,n1+n2)이며 최종(46,6)을 얻어 마지막에 나눈다. 정확한 정수에서 이 쌍의 합은 결합 순서와 묶음에 영향을 받지 않는다. 최종 건수 0에서는 평균이 정의되지 않으므로 결측 또는 오류 등 명시된 정책을 적용하고 0으로 단정하지 않는다.

10점 자가 채점 기준

- 3점: 파티션 평균 3·10과 잘못된 6.5를 1점, 올바른 46/6을 2점으로 제시한다.
- 4점: 두 중간 쌍 2점, 성분별 덧셈 결합식 1점, 최종 나눗셈 시점 1점을 설명한다.
- 3점: 최종 0건의 나눗셈 불가 2점, 명시된 별도 정책 필요 1점을 쓴다.

점수는 학습용 자가 채점이며 실제 시험 배점 재현이 아닙니다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 031회차 | 09-04 원리 I

전처리와 특징: 모델 앞에서 데이터 오류 줄이기 · 과목 31/80회차 · 기록 묶음 07의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

전처리의 목적

모델을 바꾸기 전에 데이터가 사용 시점과 목적에 맞는지 확인한다. 날짜·단위·범주 코드·키의 불일치, 중복·누락·이상치가 예측을 망칠 수 있다. 전처리의 규칙도 학습 자료에서 결정해야 할 수 있으므로 데이터 분할과 순서를 함께 설계한다.

결측값은 실제 값이 없는 상태, 0은 실제 숫자다. 결측을 무조건 0으로 채우면 "소득 미입력"을 "소득 0"으로 바꾸어 의미가 달라진다. 삭제·평균/중앙값 대체·별도 범주·결측 표시 등 방법은 누락 이유와 모델의 성질에 맞춘다. 결측과 이상치를 구분한다.

스케일과 범주

최소-최대 변환은 주어진 범위에서 (x-min)/(max-min)로 계산할 수 있다. 표준화는 (x-평균)/표준편차다. 표준화했다고 원래 분포가 반드시 정규분포가 되는 것은 아니다. 학습 자료의 평균·표준편차를 저장하고 검증·시험 자료에 같은 변환을 적용한다.

원-핫 인코딩은 범주별 지시 변수를 만든다. 지역에 부산=0,수원=1,서울=2를 부여하면 일부 모델은 임의의 순서·거리로 해석할 수 있다. 실제 순서가 없는 범주에는 그 의미를 고려한다. 지역 3개는 기본적으로 3개 지시 열로 표현할 수 있고, 특정 선형모형에서는 기준 범주를 빼는 선택이 필요할 수 있다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

보완 B03 → 115쪽

빅데이터·AI 032회차 | 09-04 원리ㅍ

전처리와 특징: 모델 앞에서 데이터 오류 줄이기 · 과목 32/80회차 · 기록 묶음 07의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

단계별 숫자 예제

학습 값이 2,4이고 이 교재 예제에서 모집단 평균 3·표준편차 1로 표준화한다. 2는 -1,4는 1이다. 시험 값 8은 학습 통계로 (8-3)/1=5가 된다. 시험 값까지 포함해 평균·표준편차를 다시 계산하면 시험 자료가 학습 과정에 영향을 주는 누수가 생긴다. 시험 값의 변환 결과가 -1~1 밖에 나오는 것은 그 자체로 오류가 아니다.

학습 값 10,12,18의 중앙값은 12다. 결측 대체 규칙을 중앙값으로 정하면 새 자료의 결측은 12로 채운다. 시험 자료에서 더 큰 값이 나타났다고 규칙을 다시 맞추지 않는다. 운영 분포가 달라지는지는 별도로 모니터링한다.

이상치와 단위

이상치는 잘못된 값일 수도 있지만 중요한 드문 사건일 수도 있다. 대규모 거래를 무조건 삭제하면 금융 위험 분석에서 필요한 사례가 사라질 수 있다. IQR 방식에서는 Q3-Q1을 기준으로 범위를 정하지만 사분위 계산 방식이 다르므로 문제의 정의를 따른다. Q1=10,Q3=20이라 주어지면 IQR=10,1.5IQR 규칙의 경계는 -5·35다. 40은 이 규칙상 경계 밖이지만 반드시 입력 오류라고 확정하지 않는다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 033회차 | 09-04 예제·적용

전처리와 특징: 모델 앞에서 데이터 오류 줄이기 · 과목 33/80회차 · 기록 묶음 07의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

단위도 중요하다. 소득 원·만원을 섞으면 차이가 10,000배다. 밀리초와 초는 1,000배다. 정상적인 큰 값과 단위 오류를 구별하려면 원천 메타데이터와 변환 규칙을 확인한다.

특징과 사용 시점

특징은 예측에 사용하는 입력 변수다. 라벨은 맞히려는 대상이다. "신청 당시 정보로 6개월 뒤 부실 여부"를 예측한다면 6개월 뒤 확정된 심사 결과는 입력에 넣으면 안 된다. 장비 예측에서는 고장 이후 수리 기록을 고장 전 입력으로 쓰면 안 된다.

자가 연습과 풀이

모든 자료를 먼저 표준화하고 그 뒤 학습/시험으로 나누면 어떤 문제가 있는가? 시험 자료의 통계가 전처리 규칙을 정하는 데 참여하여 평가가 낙관적으로 바뀔 수 있다. 분할한 뒤 학습 자료로 규칙을 정하고 검증·시험에 적용한다.

완료 기준

결측·0·이상치를 구분하고, 표준화와 원-핫을 계산하며, 전처리 통계를 어느 자료에서 학습해야 하는지 설명할 수 있어야 한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 034회차 | 09-04 직접 문제

전처리와 특징: 모델 앞에서 데이터 오류 줄이기 · 과목 34/80회차 · 기록 묶음 07의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q10

학습 평균3·표준편차1로 표준화할 때 시험 값8의 변환값은?

1. 5

2. 1

3. 8

4. -5

내 선택·근거: _____

B09Q11

전처리에서 결측값과0의 관계로 옳은 것은?

1. 실제0과 미관측은 다를 수 있으므로 누락 이유와 규칙을 확인한다.

2. 항상 같은 뜻

3. 결측은 반드시 범죄 데이터

4. 모든 결측은 삭제만 가능

내 선택·근거: _____

B09Q12

학습/시험 평가의 누수를 줄이는 전처리 순서는?

1. 전체 자료 평균으로 변환 후 분할

2. 분할 뒤 학습 부분에서 규칙을 맞추고 검증·시험에 같은 규칙을 적용

3. 시험 자료로 특징을 고른 후 학습

4. 시험 점수로 매번 평균을 바꾸기

내 선택·근거: _____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 035회차 | 09-04 해설·재현

전처리와 특징: 모델 앞에서 데이터 오류 줄이기 · 과목 35/80회차 · 기록 묶음 07의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

먼저 직접 푼 뒤 확인합니다.

B09Q10

정답: 1번

(8-3)/1=5다. 시험 자료로 통계를 다시 맞추지 않는다. 표준화 결과가 반드시 -1~1 안에 있는 것은 아니다.

B09Q11

정답: 1번

0은 실제 숫자일 수 있고 결측은 정보가 없는 상태다. 삭제·대체·표시 등 선택은 의미와 모델 조건에 달려 있다.

B09Q12

정답: 2번

전처리의 통계·특징 선택도 학습에 포함된다. 평가 자료를 먼저 사용하면 정보가 새어 성능이 낙관적으로 바뀔 수 있다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 036회차 | 09-04 원리 I

전처리와 특징: 모델 앞에서 데이터 오류 줄이기 · 과목 36/80회차 · 기록 묶음 08의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

응용 문제: 처음 보는 범주와 특징 변환

학습 자료에는 부산·수원만 있는데 운영에서 서울이 나타났다. 미지 범주를 어떻게 다룰지 변환 도구와 정책을 정해야 한다. 운영 요청마다 새 열을 임의로 만들면 학습 모델이 기대하는 열 순서·개수와 달라질 수 있다. 변환 규칙과 특징 스키마를 모델과 함께 저장한다.

정답 평균을 이용해 범주를 숫자로 만드는 target encoding은 학습·검증 경계를 잘못 다루면 라벨 누수가 생길 수 있다. 기초 단계에서는 원-핫을 먼저 이해하고, 정답을 쓰는 전처리는 왜 fold와시간 경계를 지켜야 하는지 설명하는 데 집중한다. 전처리도 모델 파이프라인의 일부다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 037회차 | 09-04 원리ㅍ

전처리와 특징: 모델 앞에서 데이터 오류 줄이기 · 과목 37/80회차 · 기록 묶음 08의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

강화 손풀이: 전처리의 숫자는 학습 자료에서 정하고 고정한다

가상 학습 자료의 한 특징은 [2, 4, 6]이다. 학습 최솟값 2와 최댓값 6을 사용해 변환값=(x-2)/(6-2)로 min-max 변환한다.

1단계 - 학습 자료를 변환한다. 2→0, 4→0.5, 6→1이다.

2단계 - 시험 자료에도 같은 규칙을 적용한다. 새 값 10은 (10-2)/4=2다. 학습 범위 밖의 값이므로 변환값이 1을 넘는다. 시험 값까지 포함해 최댓값을 10으로 다시 정하면 학습에서 정한 규칙이 달라지고 시험 정보가 전처리 학습에 들어간다. 범위를 자르는 clipping 정책이 별도로 없다면 자동으로 1이 되지 않는다.

3단계 - 결측값 처리도 같은 원칙을 적용한다. 다른 예시에서 학습 관측값은 [2, 6], 시험 관측값은 [10, 결측]이다. 평균 대치는 학습 평균 4로 결측을 채운다. 시험 관측값 10까지 합쳐 평균 6을 만드는 것은 이 분할 목적에서 허용하지 않는다. 교차검증에서도 각 회차의 학습 부분에서 대치·스케일링 규칙을 학습한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 038회차 | 09-04 예제·적용

전처리와 특징: 모델 앞에서 데이터 오류 줄이기 · 과목 38/80회차 · 기록 묶음 08의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

범주형 실무 조건. 계약상 고정된 범주 [A, B, 미지]를 세 열로 표현하고 처음 보는 범주 C는 미지 열로 보낸다고 가정한다. C의 표현은 [0, 0, 1]이다. 운영 입력에 C가 나타났다고 임의의 새 열을 추가하면 학습 모델이 기대하는 특징 열 수와 순서가 달라진다. 미지 범주를 오류로 처리하는 다른 정책도 가능하므로 정책을 먼저 명시해야 한다.

반례. 시험 자료의 결측률을 관찰하고 품질 문제를 조사하는 것과 시험 자료로 대치 평균을 학습하는 것은 구분한다. 전처리 규칙을 고정했다고 시험 분포가 학습 분포와 항상 같아지는 것도 아니다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 039회차 | 09-04 직접 문제

전처리와 특징: 모델 앞에서 데이터 오류 줄이기 · 과목 39/80회차 · 기록 묶음 08의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이·서술형 작성
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개와 서술형 1개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q34

학습 min=2, max=6으로 (x-2)/4 변환을 고정했다. clipping 없이 시험 입력 10을 변환한 값은?

1. 10

2. 1

3. 2

4. 0.5

내 선택·근거: _____

B09Q35

학습 관측 [2,6], 시험 관측 [10,결측]이다. 학습 부분의 평균만 학습해 시험 결측을 대치할 값은?

1. 4

2. 10

3. 0

4. 6

내 선택·근거: _____

B09Q36

고정 범주 열 [A,B,미지]이며 새 범주를 미지로 보내는 계약이다. C 입력의 올바른 처리와 특징 차원은?

1. [0,0,0,1], C 열 추가

2. [0,0,1], 세 열 유지

3. [1,0,0], A로 대체

4. 범주가 새로 생기면 원래 열 순서를 임의로 바꾼다.

내 선택·근거: _____

W09Q04

학습 min=2·max=6으로 변환하고 clipping은 없다. 시험 입력 10을 계산하라. 별도 학습 관측[2,6]·시험[10,결측]의 평균 대치값을 계산하고, 처음 보는 범주 처리에서 필요한 계약을 설명하라.

조건·원리·중간 과정·결론 순서로 먼저 답안을 작성합니다.

내 답안: _____

_____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 040회차 | 09-04 해설·재현

전처리와 특징: 모델 앞에서 데이터 오류 줄이기 · 과목 40/80회차 · 기록 묶음 08의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

서술형 모범답안과 자가 채점 기준

B09Q34

정답: 3번

정답 근거: (10-2)/4=2다. 시험 입력이 학습 범위를 벗어나면 1보다 클 수 있다.

「1」 - 1은 새 최댓값 10으로 다시 학습하거나 값을 자를 때만 두 조건 모두 주어지지 않았다.

「0.5」 - 0.5는 입력 4의 변환값이다.

「10」 - 원래 입력값을 변환 없이 반환한 결과다.

B09Q35

정답: 1번

정답 근거: 학습 관측 평균은 (2+6)/2=4다. 시험 관측은 규칙 학습에 넣지 않는다.

「6」 - 6은 시험의 10까지 함께 학습한 평균으로 이 조건에 어긋난다.

「10」 - 시험 관측 하나만 사용해 대치 규칙을 정했다.

「0」 - 평균 대치라는 규칙에는 0을 선택할 근거가 없다.

B09Q36

정답: 2번

정답 근거: 계약에 따라 미지 열만 1이며 모델이 기대하는 세 열과 순서를 유지한다.

「[0,0,0,1], C 열 추가」 - C 열 추가는 고정된 세 열 계약을 깨고 모델 입력 차원을 바꾼다.

「[1,0,0], A로 대체」 - C를 A로 보내라는 규칙은 없다.

「범주가 새로 생기면 원래 열 순서를 임의로 바꾼다.」 - 열 순서도 특징 의미의 일부이며 임의로 바꾸면 계약을 깨뜨린다.

W09Q04

학습 min=2·max=6으로 변환하고 clipping은 없다. 시험 입력 10을 계산하라. 별도 학습 관측[2,6]·시험[10,결측]의 평균 대치값을 계산하고, 처음 보는 범주 처리에서 필요한 계약을 설명하라.

모범답안

min-max 변환은 (10-2)/(6-2)=2이며 학습 범위 밖 입력은 1을 넘을 수 있다. 별도 평균 대치는 학습 평균 (2+6)/2=4를 사용한다. 시험 10까지 학습에 넣어 6을 사용하는 것은 이 분할에서 정보 누수다. 범주를 미지 열로 보내거나 오류로 처리할 정책을 미리 정하고 학습 때 고정한 특징 열 수·순서를 유지한다. 교차검증에서도 회차마다 학습 부분으로 전처리를 학습한다.

10점 자가 채점 기준

- 3점: 변환식과 값 2를 2점, clipping 없이 1초과 가능을 1점으로 설명한다.
- 4점: 학습 평균 4를 2점, 시험을 넣은 6의 누수 문제를 2점으로 설명한다.
- 3점: 미지 범주 정책 1점, 특징 차원·순서 유지 1점, 교차검증 회차의 학습 부분 사용 1점을 쓴다.

점수는 학습용 자가 채점이며 실제 시험 배점 재현이 아닙니다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 041회차 | 09-05 원리 I

회귀·분류·학습: 모델은 무엇을 최적화하는가 · 과목 41/80회차 · 기록 묶음 09의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

학습 유형

지도학습은 입력과 정답을 이용해 관계를 학습한다. 회귀는 연속 수치 예측, 분류는 범주 예측이 중심이다. 비지도학습은 정답 범주 없이 구조를 찾으며 군집·차원축소가 대표적인 사례다. 강화학습은 행동과 보상의 상호작용을 다루지만 이 교재에서는 우선순위가 낮은 개념 소개에 그친다.

신청액 예측은 회귀, 승인·거절 범주 예측은 분류, 비슷한 거래 패턴의 그룹 탐색은 군집으로 볼 수 있다. 숫자로 표시된 범주를 예측한다고 모두 회귀가 되는 것은 아니다. 결과의 의미와 문제 목적을 본다.

선형회귀와 손실

단순 선형모형은 y_pred=w×x+b로 표현할 수 있다. 손실은 예측과 정답의 차이를 수치화한다. MSE는 오차 제곱의 평균, MAE는 절댓값 오차의 평균이다. 제곱 오차는 큰 오류를 더 크게 벌점화한다. 서로 단위와 민감도가 다르므로 숫자 크기만 직접 비교하지 않는다.

단계별 계산

x=1,2일 때 실제 y는 4,4,모형은 y_pred=2x+1이라고 하자. 예측은 3,5,오차 y_pred-y는 -1,1이다. MSE=(1+1)/2=1,MAE=(1+1)/2=1이다. 예측 2,5와 실제 3,3이라면 오차는 -1,2,MSE=(1+4)/2=2.5,MAE=(1+2)/2=1.5다. 같은 두 지표가 항상 같지는 않다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

보완 B04 → 116쪽

빅데이터·AI 042회차 | 09-05 원리ㅍ

회귀·분류·학습: 모델은 무엇을 최적화하는가 · 과목 42/80회차 · 기록 묶음 09의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

기울기를 학습하는 경사하강법은 손실이 감소하는 방향으로 파라미터를 조금씩 갱신한다. 업데이트를 w_new=w_old-learning_rate×gradient로 쓰고 w_old=2,learning_rate=0.1,gradient=3이라면 w_new=1.7이다. 학습률이 너무 크면 불안정해질 수 있고 너무 작으면 느릴 수 있다. 한 번의 갱신으로 항상 전역 최적값에 도달하는 것은 아니다.

로지스틱 회귀와 분류

로지스틱 회귀는 이름에 회귀가 있지만 대표적으로 이진 분류에 쓰인다. 점수 z를 sigmoid(z)=1/(1+exp(-z))로 변환한다. z=0이면 0.5다. 이 값을 기준 임계값과 비교해 범주로 바꿀 수 있다. 출력 수치가 좋은 확률로 해석되려면 학습·보정·분포의 조건도 봐야 한다.

임계값 0.5를 0.7로 올리면 같은 점수에서 양성으로 분류되는 수는 일반적으로 줄어든다. 업무마다 거짓 경보와 놓친 위험의 비용이 다르므로 0.5가 항상 최선은 아니다. 손실함수·학습 파라미터·결정 임계값을 구분한다.

다른 모델의 큰 그림

결정트리는 특징 조건으로 데이터를 나누고 잎에서 예측한다. 깊어지면 복잡한 관계를 표현하지만 과적합 위험이 커질 수 있다. k-NN은 가까운 학습 사례를 바탕으로 예측하며 거리와 스케일에 민감하다. 앙상블은 여러 모형을 결합한다. 신경망은 여러 비선형 변환의 파라미터를 학습한다. 어떤 모델도 자료가 잘못되거나 평가가 누수되면 자동으로 신뢰할 수 없다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 043회차 | 09-05 예제·적용

회귀·분류·학습: 모델은 무엇을 최적화하는가 · 과목 43/80회차 · 기록 묶음 09의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

자가 연습과 풀이

부실 여부를 0·1로 표시했다고 "연속 수치이므로 회귀 문제"라고 단정하면 안 된다. 업무상 두 범주를 구분하는 분류 문제다. 불량률이라는 연속 비율 자체를 예측하는 목표와 구분한다.

완료 기준

지도·비지도와 회귀·분류의 차이를 말하고 MSE·MAE·한 번의 경사하강 업데이트를 직접 계산한다. 로지스틱 회귀의 출력과 결정 임계값을 서로 구분해야 한다.

응용 계산: 정규화 항의 역할

가상 목적함수를 J=MSE+lambda×(w1^2+w2^2)로 정의하고 절편은 벌점에서 제외한다.
MSE=1,w1=2,w2=-1,lambda=0.5라면 J=1+0.5×(4+1)=3.5다. 파라미터 크기에도 비용을 주는 것으로, 학습 오차만 무조건 0으로 만드는 목표와 다르다.

lambda가 커지면 계수 크기를 더 강하게 억제하는 경향이 있지만 모든 데이터에서 검증 성능이 계속 개선되는 것은 아니다. 학습률은 업데이트 크기,lambda는 정규화 강도다. 두 값을 같은 것으로 외우지 않는다. 시험에 손실 합/평균 또는 1/2 계수가 주어지면 그 정의를 따른다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 044회차 | 09-05 직접 문제

회귀·분류·학습: 모델은 무엇을 최적화하는가 · 과목 44/80회차 · 기록 묶음 09의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q13

예측2·5,실제3·3일 때 MSE와 MAE는?

1. 1.5와2.5

2. 2.5와1.5

3. 3과3

4. 1과1

내 선택·근거: _____

B09Q14

w=2,학습률0.1,기울기3이며 w_new=w-learning_rate×gradient일 때 새 w는?

1. 2.3

2. 3

3. 0.6

4. 1.7

내 선택·근거: _____

B09Q15

로지스틱 회귀에 대한 설명으로 옳은 것은?

1. 이진 분류에 쓰이며 sigmoid(0)=0.5이고 임계값 선택은 별도다.

2. 이름이 회귀이므로 이진 분류에 쓸 수 없다.

3. sigmoid(0)은0이다.

4. 확률 출력은 항상 완벽히 보정된다.

내 선택·근거: _____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 045회차 | 09-05 해설·재현

회귀·분류·학습: 모델은 무엇을 최적화하는가 · 과목 45/80회차 · 기록 묶음 09의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

먼저 직접 푼 뒤 확인합니다.

B09Q13

정답: 2번

오차-1·2의 제곱 평균=(1+4)/2=2.5,절댓값 평균=(1+2)/2=1.5다.

B09Q14

정답: 4번

2-0.1×3=1.7이다. 가중치에서 학습률과 기울기의 곱을 뺀다. 한 번의 갱신이 최적성을 보장하지는 않는다.

B09Q15

정답: 1번

로지스틱 회귀는 대표적 이진 분류 모델이다. sigmoid(0)=1/(1+1)=0.5다. 모형 점수·확률 보정·결정 임계값을 구분한다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 046회차 | 09-05 원리 I

회귀·분류·학습: 모델은 무엇을 최적화하는가 · 과목 46/80회차 · 기록 묶음 10의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

강화 손풀이: 손으로 한 번 경사하강을 수행한다

절편 없는 예측식은 y_hat=wx이고 자료는 (x,y)=(1,2),(2,4)다. 손실은 두 관측의 제곱오차 평균 L(w)=[(w-2)^2+(2w-4)^2]/2로 정의한다. 정규화 항은 없다.

1단계 - 시작점 w=1의 손실. 예측은 1, 2이고 오차는 -1, -2다. L(1)=(1+4)/2=2.5다. 같은 지점의 MAE는 (1+2)/2=1.5로 MSE와 다르다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 047회차 | 09-05 원리ㅍ

회귀·분류·학습: 모델은 무엇을 최적화하는가 · 과목 47/80회차 · 기록 묶음 10의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

2단계 - 미분. dL/dw=[2(w-2)+4(2w-4)]/2=5w-10이다. w=1에서 기울기는 -5다.

3단계 - 학습률 0.1로 갱신. w새=w-0.1×기울기=1-0.1×(-5)=1.5다. 새 예측은 1.5, 3이고 새 손실은 (0.25+1)/2=0.625다. 음수 기울기를 빼므로 w가 증가한다.

4단계 - 학습률 반례. 같은 시작점에서 학습률을 1로 바꾸면 w새=6, 손실은 (16+64)/2=40으로 증가한다. 학습률을 크게 하면 항상 빨리 좋은 해에 도달한다는 주장은 틀린다. 이 수치 예시는 모든 모델의 안전 학습률을 알려주지는 않는다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 048회차 | 09-05 예제·적용

회귀·분류·학습: 모델은 무엇을 최적화하는가 · 과목 48/80회차 · 기록 묶음 10의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

정규화 조건. 만약 목표가 L(w)+0.1w^2라면 기울기는 5w-10+0.2w다. 처음에는 -4.8, 학습률 0.1의 새 w는 1.48이다. 손실 정의가 바뀌면 계산도 바뀐다. w는 자료로 학습하는 모델 매개변수이고 학습률과 정규화 강도는 학습 절차를 정하는 하이퍼파라미터다. 검증 자료로 절차를 선택한 뒤 시험 자료는 최종 평가에 사용한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 049회차 | 09-05 직접 문제

회귀·분류·학습: 모델은 무엇을 최적화하는가 · 과목 49/80회차 · 기록 묶음 10의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이·서술형 작성
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개와 서술형 1개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q37

y_hat=wx, 자료 (1,2),(2,4), 손실 MSE, 정규화 없음이다. w=1, 학습률 0.1의 기울기와 한 번 갱신한 w는?

1. -5, 0.5

2. -10, 2

3. -5, 1.5

4. 5, 0.5

내 선택·근거: _____

B09Q38

y_hat=wx, 자료 (1,2),(2,4), 손실 L(w)=[(w-2)^2+(2w-4)^2]/2이며 정규화는 없다. w=1에서 학습률 1로 한 번 갱신하면 w=6이다. 새 손실과 해석은?

1. 2.5이며 매개변수를 바꿔도 손실은 같다.

2. 0.625이며 큰 학습률은 항상 더 좋다.

3. 0이며 목표 y가 모두 양수이기 때문이다.

4. 40이며 학습률을 키워 손실이 커질 수 있다.

내 선택·근거: _____

B09Q39

y_hat=wx, 자료 (1,2),(2,4), L(w)=[(w-2)^2+(2w-4)^2]/2이다. 목표를 L(w)+0.1w^2로 바꿨다. w=1, 학습률 0.1에서 기울기와 한 번 갱신한 값으로 옳은 것은?

1. 새 w는 0.52다.

2. 기울기는 -4.8이며 새 w는 1.48이다.

3. 정규화 강도 0.1은 반드시 자료로 학습되는 w와 같은 종류다.

4. 정규화는 목표만 바꾸며 기울기는 항상 -5다.

내 선택·근거: _____

W09Q05

y_hat=wx, 자료(1,2),(2,4), 평균 제곱오차이며 정규화는 없다. w=1에서 손실·기울기·학습률 0.1 갱신값·새 손실을 계산하라. 학습률 1의 갱신값과 손실로 반례도 설명하라.

조건·원리·중간 과정·결론 순서로 먼저 답안을 작성합니다.

내 답안: _____

_____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 050회차 | 09-05 해설·재현

회귀·분류·학습: 모델은 무엇을 최적화하는가 · 과목 50/80회차 · 기록 묶음 10의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

서술형 모범답안과 자가 채점 기준

B09Q37

정답: 3번

정답 근거: 평균 제곱오차의 미분은 5w-10, 시작점에서 -5다. 1-0.1×(-5)=1.5다.

「-5, 0.5」 - 음수 기울기를 빼는 갱신의 부호를 반대로 적용했다.

「-10, 2」 - 합 제곱오차의 기울기 -10을 평균 손실에 적용했다.

「5, 0.5」 - 오차의 방향을 반대로 잡아 기울기 부호를 잘못 계산했다.

B09Q38

정답: 4번

정답 근거: 예측 6,12의 오차 4,8을 제곱해 평균하면 (16+64)/2=40이다.

「0.625이며 큰 학습률은 항상 더 좋다.」 - 0.625는 학습률 0.1로 w=1.5가 되었을 때의 값이다.

「0이며 목표 y가 모두 양수이기 때문이다.」 - 양수 목표는 모든 양수 매개변수가 정답이라는 뜻이 아니다.

「2.5이며 매개변수를 바꿔도 손실은 같다.」 - 2.5는 시작점 w=1의 값이며 갱신 후 값과 다르다.

B09Q39

정답: 2번

정답 근거: 기존 -5에 정규화 미분 0.2w=0.2를 더해 -4.8, 갱신은 1+0.48=1.48이다.

「정규화는 목표만 바꾸며 기울기는 항상 -5다.」 - 미분 가능한 정규화 항도 최적화 기울기에 영향을 준다.

「새 w는 0.52다.」 - 음수 기울기를 빼는 부호를 뒤집은 값이다.

「정규화 강도 0.1은 반드시 자료로 학습되는 w와 같은 종류다.」 - 이 예시에서 w는 학습 매개변수, 정규화 강도는 학습 절차를 정하는 하이퍼파라미터다.

W09Q05

y_hat=wx, 자료(1,2),(2,4), 평균 제곱오차이며 정규화는 없다. w=1에서 손실·기울기·학습률 0.1 갱신값·새 손실을 계산하라. 학습률 1의 갱신값과 손실로 반례도 설명하라.

모범답안

시작 오차는 -1,-2이고 MSE는 2.5다. L(w)=[(w-2)^2+(2w-4)^2]/2, 미분 5w-10은w=1에서 -5다. 학습률 0.1은 w=1-0.1×(-5)=1.5이고 새 MSE는(0.25+1)/2=0.625다. 학습률 1이면 w=6, MSE=(16+64)/2=40으로 증가한다. 따라서 큰 학습률이 항상 손실을 줄이는 것은 아니다.

10점 자가 채점 기준

- 3점: 시작 손실 2.5를 1점, 평균 손실 미분과 기울기-5를 2점으로 계산한다.
- 3점: 올바른 갱신 부호와w=1.5를 2점, 새 손실 0.625를 1점으로 제시한다.
- 4점: 학습률 1의 w=6을 1점, 손실 40을 2점, 큰 학습률의 보장 불가를 1점으로 설명한다.

점수는 학습용 자가 채점이며 실제 시험 배점 재현이 아닙니다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 051회차 | 09-06 원리 I

학습·검증·시험 분리와 누수: 좋은 점수의 함정 · 과목 51/80회차 · 기록 묶음 11의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

데이터 분할의 역할

학습 세트는 모델 파라미터를 맞추는 데 사용한다. 검증 세트는 모델·하이퍼파라미터·임계값 등을 선택하는 데 사용한다. 시험 세트는 최종 선택한 절차를 평가하는 데 사용한다. 시험 점수를 보면서 반복 선택하면 시험 자료가 사실상 검증 역할에 참여하여 독립 평가가 약해진다.

하이퍼파라미터는 학습률·트리 깊이·정규화 강도 등 학습·모델 설정이다. 파라미터는 학습으로 결정되는 가중치 등의 값이다. 분류 임계값도 업무 평가와 모델 선택에 연결되므로 최종 시험 결과를 보고 임의로 튜닝하지 않는다.

누수의 종류

데이터 누수는 예측 시점에 사용할 수 없는 정보나 평가 자료의 정보가 학습·선택 과정에 들어가는 문제다. 미래 결과를 입력에 넣는 목표 누수, 전처리를 전체 자료에서 맞추는 누수, 동일 고객·장비의 거의 같은 자료가 양쪽에 들어가는 그룹 누수 등을 생각할 수 있다.

시계열 예측은 시간 순서가 중요하다. 1~6월로 학습하고 7월로 검증하며 8월로 시험하는 방식은 미래 자료가 과거 예측에 들어가는 위험을 줄인다. 모든 데이터에서 무작위 분할이 항상 나쁘다는 뜻이 아니라 사용 목적과 의존성을 확인한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

보완 B05 → 117쪽

빅데이터·AI 052회차 | 09-06 원리ㅍ

학습·검증·시험 분리와 누수: 좋은 점수의 함정 · 과목 52/80회차 · 기록 묶음 11의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

단계별 금융 사례

6개월 뒤 연체를 예측하려는데 입력에 "6개월 뒤 회수 담당자 배정 여부"가 포함됐다. 그 값은 예측 시점 이후에 결정될 수 있으므로 누수다. 같은 고객의 여러 신청을 무작위로 나누면 학습에서 본 고객의 특성을 시험에서 다시 보게 될 수 있다. 새로운 고객 일반화가 목표라면 고객 단위 분리가 적절한지 검토한다.

장비 이미지에서는 같은 원본에서 만든 작은 변형 이미지가 학습·시험 양쪽에 있으면 성능이 과대평가될 수 있다. 원본·생산 lot·장비·촬영 시점 등 목표에 맞는 그룹 경계를 고려한다.

과적합·과소적합

과적합은 학습 자료의 우연한 특징까지 맞춰 새로운 자료에 일반화하지 못하는 상태다. 과소적합은 관계를 충분히 표현하지 못하는 상태다. 학습 오차가 낮고 검증 오차가 높으면 과적합을 의심하지만 분포 변화·누수·라벨 오류 같은 다른 원인도 확인한다.

정규화·모델 복잡도 제한·더 적절한 자료·조기 종료 등이 도움을 줄 수 있다. 정규화는 무조건 오차를 0으로 만드는 기법이 아니다. 편향·분산의 관점은 모형의 제한과 자료 변동에 대한 민감도를 이해하게 한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 053회차 | 09-06 예제·적용

학습·검증·시험 분리와 누수: 좋은 점수의 함정 · 과목 53/80회차 · 기록 묶음 11의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

교차검증 예제

자료 100개를 5개의 fold로 나눠 각 20개를 검증에 쓰면 매 반복 학습 80·검증 20개다. 다섯 평가값의 평균으로 설정을 비교할 수 있다. 전처리도 매 fold의 학습 부분에서 학습해야 한다. 전체 자료에서 특징 선택을 먼저 한 뒤 교차검증하면 검증 자료의 정보가 들어갈 수 있다. 시계열·그룹 구조가 있으면 그 구조를 지키는 분할 방법을 사용한다.

성능이 학습 99%,검증 70%라면 일반화 차이가 29%p다. "29% 감소"라고 쓸 때 상대 감소와 %p 차이를 혼동하지 않는다. 데이터와 평가 방식부터 확인한 뒤 모델 복잡도를 조절한다.

자가 연습과 풀이

시험 세트로 임계값을 20번 비교해 가장 좋은 값을 고르면 최종 점수를 독립 시험 성능으로 그대로 보고해도 될까? 선택 과정에 시험 자료가 참여했으므로 적절한 검증 구분이나 새로운 최종 평가가 필요하다.

완료 기준

세 세트의 역할을 설명하고 시간·고객·원본 이미지 누수를 찾으며, 교차검증에서 전처리를 어디서 맞춰야 하는지 말할 수 있어야 한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 054회차 | 09-06 직접 문제

학습·검증·시험 분리와 누수: 좋은 점수의 함정 · 과목 54/80회차 · 기록 묶음 11의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q16

시험 세트의 가장 적절한 사용 목적은?

1. 매 반복 학습 가중치를 맞추기

2. 최종 선택한 절차를 독립적으로 평가

3. 20개 임계값 중 최적을 고르기

4. 전처리 평균을 맞추기

내 선택·근거: _____

B09Q17

자료100개를5fold로 나누어 한fold를 검증하는 각 반복의 학습/검증 개수는?

1. 20/80

2. 80/20

3. 100/0

4. 50/50

내 선택·근거: _____

B09Q18

신청 시점 정보로6개월뒤 연체를 예측하면서6개월뒤 회수 담당자 배정 여부를 입력에 넣었다. 주된 문제는?

1. 원-핫 인코딩 부족만

2. 무조건 좋은 성능 개선

3. k-means의 군집 개수

4. 예측 시점 이후 정보에 의한 누수

내 선택·근거: _____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 055회차 | 09-06 해설·재현

학습·검증·시험 분리와 누수: 좋은 점수의 함정 · 과목 55/80회차 · 기록 묶음 11의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

먼저 직접 푼 뒤 확인합니다.

B09Q16

정답: 2번

시험은 최종 평가용이다. 학습은 파라미터,검증은 설정·임계값 선택에 사용한다. 시험 자료를 선택에 반복 쓰면 독립성이 약해진다.

B09Q17

정답: 2번

5fold 각20개 중1개fold20을 검증하고나머지80을 학습한다. 전처리도 해당 학습80에서 맞춰야 한다.

B09Q18

정답: 4번

입력이 예측 시점에 알려지지 않는다면 목표·시간 누수다. 높은 점수여도 실제 사용 시점에 재현하기 어렵다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 056회차 | 09-06 원리 I

학습·검증·시험 분리와 누수: 좋은 점수의 함정 · 과목 56/80회차 · 기록 묶음 12의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

응용 문제: 설정 선택과 보고

검증 점수로 모델 A·B·C 중 B를 골랐다. 이제 B를 고정해 최종 시험한다. 이후 시험 결과를 보고 C로 교체했다면 처음 설계한 독립 평가의 목적이 약해진다. 비교·선택·보고 자료의 역할을 분리하고 필요하면 새 평가 자료나 적절한 중첩 검증을 사용한다.

배포 후 성능이 떨어져도 무조건 과적합 때문이라고 단정하지 않는다. 입력 분포 변화, 라벨 정의 변화, 누락률 증가, 전처리 버전 불일치가 원인일 수 있다. 학습·검증 손실과 운영 자료 품질을 함께 확인하면 원인 추정에 도움이 된다.

강화 손풀이: 레코드 수보다 배치될 환경을 먼저 정한다

가상 고객 6명에게 각각 4개의 기록이 있어 총 24개다. 목적은 **학습 때 보지 못한 새 고객에 대한 성능**을 평가하는 것이다. 고객 ID 외의 특징으로 예측하더라도 같은 고객의 반복 기록은 서로 비슷할 수 있다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 057회차 | 09-06 원리ㅍ

학습·검증·시험 분리와 누수: 좋은 점수의 함정 · 과목 57/80회차 · 기록 묶음 12의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

1단계 - 분할 단위를 고객으로 정한다. 학습 고객 4명, 검증 고객 1명, 시험 고객 1명을 서로 겹치지 않게 배치하면 기록 수는 16, 4, 4다. 레코드를 무작위로 섞어 같은 고객이 세 집합에 들어가면 새 고객 평가라는 목적을 충족하지 않는다. 다만 6명뿐인 이 예시는 안정적인 일반화 성능을 확정하기에는 작다.

2단계 - 시간 목적이면 별도 설계한다. 이미 관찰한 고객의 미래를 예측하는 다른 문제에서는 과거로 학습하고 이후 시점으로 평가하는 설계가 필요하다. 두 문제는 분할 목표가 다르다. 고객 분리와 시간 순서를 동시에 요구하면 해당 조건을 모두 만족하는 자료가 있는지 확인해야 한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 058회차 | 09-06 예제·적용

학습·검증·시험 분리와 누수: 좋은 점수의 함정 · 과목 58/80회차 · 기록 묶음 12의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

3단계 - 학습 가능한 변환을 안쪽에 넣는다. 각 교차검증 회차에서 대치 평균·스케일·특징 선택은 해당 학습 부분으로 정하고 그 회차의 검증 부분에 적용한다. 분할 전에 전체 자료로 특징을 고르면 검증 부분의 정보가 이미 선택 과정에 쓰인다.

4단계 - 시험 자료를 반복 선택에 쓰지 않는다. 시험 점수를 20번 보고 모델을 고른다면 그 시험 집합은 선택에 관여했다. 같은 집합의 최고 점수를 독립적인 최종 성능 추정이라고 부르기 어렵다. 검증/교차검증으로 선택하고 가능하면 별도로 보존한 최종 자료로 평가한다.

반례. ID 열을 삭제했다는 사실만으로 고객 간 정보가 독립이라는 보장은 없다. 동일 장비의 연속 영상이나 같은 생산 LOT의 반복 검사에서도 목적에 맞는 그룹·시간 경계를 검토해야 한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 059회차 | 09-06 직접 문제

학습·검증·시험 분리와 누수: 좋은 점수의 함정 · 과목 59/80회차 · 기록 묶음 12의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이·서술형 작성
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개와 서술형 1개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q40

새 고객 평가가 목적이며 고객 6명이 각각 4개의 기록을 가진다. 학습 4명·검증 1명·시험 1명을 겹치지 않게 배정한 기록 수는?

1. 4, 1, 1

2. 16, 4, 4

3. 18, 3, 3

4. 24, 24, 24

내 선택·근거: _____

B09Q41

새 고객 평가에서 ID 열은 삭제했지만 같은 고객의 반복 기록을 학습과 시험에 나눴다. 가장 적절한 판단은?

1. ID 삭제만으로 새 고객 평가가 보장되지 않으므로 고객 그룹 경계를 다시 검토한다.

2. ID가 없으므로 고객 반복 정보도 반드시 사라졌다.

3. 시험 기록이 하나라도 있으면 분할 목적은 충족한다.

4. 항상 모든 고객을 세 집합에 각각 넣어야 새 고객 평가가 된다.

내 선택·근거: _____

B09Q42

시험 점수를 20번 확인하며 가장 좋은 모델을 선택했다. 적절한 설명은?

1. 전처리를 전체 자료에서 학습하면 이 문제가 자동으로 해결된다.

2. 시험이라는 이름을 붙였으므로 선택에 써도 항상 독립이다.

3. 그 시험 집합이 모델 선택에 관여해 독립적인 최종 평가로 해석하기 어렵다.

4. 최고 점수는 어떤 미래 집단에도 같은 성능을 보장한다.

내 선택·근거: _____

W09Q06

새 고객 평가를 위해 고객 6명·고객당 4기록을 학습 4명·검증 1명·시험 1명으로 나누려 한다. 분할 단위와 기록 수, 전처리 학습 위치, 시험 점수 반복 선택의 문제를 설명하라.

조건·원리·중간 과정·결론 순서로 먼저 답안을 작성합니다.

내 답안: _____

_____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 060회차 | 09-06 해설·재현

학습·검증·시험 분리와 누수: 좋은 점수의 함정 · 과목 60/80회차 · 기록 묶음 12의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

서술형 모범답안과 자가 채점 기준

B09Q40

정답: 2번

정답 근거: 각 고객 기록 4개를 같은 집합에 유지하므로 고객 수에 4를 곱한다.

「4, 1, 1」 - 고객 수를 기록 수로 오인했다.

「18, 3, 3」 - 같은 크기의 고객 묶음을 유지하면 3개 기록의 집합은 만들 수 없다.

「24, 24, 24」 - 서로 겹치지 않게 배정하므로 전체 24개를 세 집합에 반복해서 넣지 않는다.

B09Q41

정답: 1번

정답 근거: 반복 기록의 특징 자체에 고객 공통 정보가 남을 수 있고 시험 고객을 학습 때 이미 본 셈이므로 분할 목적을 확인한다.

「ID가 없으므로 고객 반복 정보도 반드시 사라졌다.」 - 특정 ID 열 삭제와 모든 고객 관련 상관 정보 제거는 같은 조건이 아니다.

「시험 기록이 하나라도 있으면 분할 목적은 충족한다.」 - 시험 집합의 존재와 새 고객이라는 배치 목적의 충족은 다르다.

「항상 모든 고객을 세 집합에 각각 넣어야 새 고객 평가가 된다.」 - 모든 집합에 같은 고객을 넣으면 학습에서 보지 못한 고객의 평가라는 목적을 깨뜨린다.

B09Q42

정답: 3번

정답 근거: 점수가 선택을 바꾸었으므로 시험 자료의 정보가 학습 절차에 들어갔다. 별도 최종 평가를 설계한다.

「시험이라는 이름을 붙였으므로 선택에 써도 항상 독립이다.」- 집합의 이름이 실제 정보 사용을 독립적으로 만들지 않는다.

「최고 점수는 어떤 미래 집단에도 같은 성능을 보장한다.」- 관측 점수는 미래 분포·표본 변동·선택 편향까지 제거하는 보장이 아니다.

「전처리를 전체 자료에서 학습하면 이 문제가 자동으로 해결된다.」- 전체 자료 전처리 학습은 오히려 다른 정보 누수를 추가할 수 있다.

W09Q06

새 고객 평가를 위해 고객 6명·고객당 4기록을 학습 4명·검증 1명·시험 1명으로 나누려 한다. 분할 단위와 기록 수, 전처리 학습 위치, 시험 점수 반복 선택의 문제를 설명하라.

모범답안

고객을 겹치지 않게 배정하고 동일 고객의 4기록을 같은 집합에 둔다. 기록 수는 16·4·4다. 교차검증의 대치·스케일링·특징 선택은 해당 회차의 학습 부분에서 정하고 검증 부분에 적용한다. 시험 점수를 반복 보고 모델을 선택하면 시험 정보가 선택에 관여하므로 독립적인 최종 평가로 해석하기 어렵다. ID 삭제만으로 고객 정보가 사라지지는 않으며 고객 수가 적은 예시로 안정적인 일반화 성능을 단정할 수도 없다.

10점 자가 채점 기준

- 3점: 고객 그룹 경계와 기록 동반 배치를 2점, 기록 수 16·4·4를 1점으로 쓴다.
- 3점: 회차의 학습 부분으로 전처리를 학습 2점, 검증에는 고정 적용 1점을 설명한다.
- 4점: 시험 정보의 선택 관여 2점, 독립 평가 해석의 한계 1점, ID 삭제 또는 작은 고객 표본의 한계 1점을 쓴다.

점수는 학습용 자가 채점이며 실제 시험 배점 재현이 아닙니다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 061회차 | 09-07 원리 I

분류 평가와 불균형: 정밀도·재현율·F1 계산하기 · 과목 61/80회차 · 기록 묶음 13의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

혼동행렬을 먼저 고정

양성은 분석자가 중요하게 보는 범주다. 여기서는 위험 거래를 양성이라고 정한다. TP는 실제 위험을 위험으로 판단, FP는 정상 거래를 위험으로 판단, FN은 위험을 정상으로 놓침, TN은 정상 거래를 정상으로 판단한 수다. 양성을 무엇으로 정의했는지 바꾸면 해석도 바뀐다.

정확도=(TP+TN)/전체,정밀도=TP/(TP+FP),재현율=TP/(TP+FN),F1=2TP/(2TP+FP+FN)이다. 특이도는 TN/(TN+FP),거짓 양성률은 FP/(FP+TN)이다. 분모가 0이면 지표 정의와 도구의 정책을 확인하며 임의로 모두 100%라고 쓰지 않는다.

단계별 숫자 예제

200건 중 TP=24,FP=6,FN=16,TN=154다. 예측 양성은 30건,실제 양성은 40건이다. 정밀도는 24/30=80%,재현율은 24/40=60%다. F1은 48/(48+6+16)=48/70 약 68.57%다. 정확도는 (24+154)/200=89%다. 특이도는 154/160=96.25%다. 정밀도·재현율의 평균 70%는 F1과 다르다. F1은 조화평균이다.

불균형 자료의 함정

전체 1,000건 중 위험이 10건인데 모두 정상이라고 예측하면 정확도는 990/1,000=99%다. 위험을 한 건도 찾지 못하므로 재현율은 0이다. 예측 양성이 0건이면 정밀도의 분모도 0이다. 높은 정확도가 유용한 위험 탐지를 뜻하지 않는다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 062회차 | 09-07 원리ㅍ

분류 평가와 불균형: 정밀도·재현율·F1 계산하기 · 과목 62/80회차 · 기록 묶음 13의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

금융 위험·장비 불량 탐지에서는 놓침과 오탐의 비용이 다를 수 있다. 실제 정책과 검토 인력을 함께 고려해야 한다. 일반적인 예로 위험 놓침이 더 비싸면 재현율을 더 중시할 수 있지만, 모든 기관·모든 업무가 같은 비용 구조라는 단정은 하지 않는다.

임계값과 곡선

확률 점수에 대한 임계값을 낮추면 양성으로 분류되는 집합이 넓어진다. 고정된 점수에서 TP·FP가 감소하지 않는 방향이므로 재현율은 내려가지 않는다. 정밀도는 자료에 따라 반드시 한 방향으로 움직인다고 수학적으로 단정할 수 없다. 흔히 둘 사이 절충이 나타나지만 개별 표본에 따라 다르다.

ROC는 임계값에 따른 재현율(TPR)과 거짓 양성률(FPR)을 그린다. AUC는 순위 판별 성능과 관련된 요약값이다. 임계값 한 개의 정확도와 동일하지 않다. 클래스 불균형에서는 Precision-Recall 곡선도 중요하게 검토한다. AUC가 높다고 개별 업무의 비용·보정·공정성까지 자동으로 적합한 것은 아니다.

비용 예제

모델 A는 FP=20,FN=5,모델 B는 FP=5,FN=12다. FP 한 건 비용 1,FN 한 건 비용 10이라는 가상 조건이면 A 비용은 20+50=70,B는 5+120=125다. 이 조건에서는 A가 낫다. 비용이 달라지면 판단도 달라질 수 있다. 단순 비용 계산을 실제 금융 의사결정의 전체 근거로 삼는 것은 아니다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

보완 B07 → 119쪽

빅데이터·AI 063회차 | 09-07 예제·적용

분류 평가와 불균형: 정밀도·재현율·F1 계산하기 · 과목 63/80회차 · 기록 묶음 13의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

자가 연습과 풀이

경보를 받은 30건 중 실제 위험 24건이라는 문장은 정밀도다. 실제 위험 40건 중 찾은 24건이라는 문장은 재현율이다. 분모의 의미를 한국어 문장으로 바꾸는 연습을 하자. "정밀도가 높으니 위험을 거의 다 찾았다"는 해석은 두 지표를 혼동했다.

완료 기준

혼동행렬을 스스로 그리고 5개 지표를 계산한다. 불균형 사례에서 정확도 99%의 문제와 업무 비용에 따른 임계값 선택 이유를 설명할 수 있어야 한다.

응용 계산: 균형 정확도와 평균 방식

TP24,FN16,TN154,FP6의 예제에서 재현율은 0.6, 특이도는 0.9625다. 이진 분류의 균형 정확도를 두 값의 평균으로 정의하면 (0.6+0.9625)/2=0.78125, 즉 78.125%다. 전체 정확도 89%와 다르다.

여러 범주의 F1을 평균할 때 macro는 범주별 지표의 단순 평균, weighted는 범주 지원 수로 가중한 평균, micro는 전체 TP·FP·FN을 모아 계산하는 관점이다. 서로 다른 평균 방식을 같은 숫자로 비교하면 안 된다. 특히 큰 정상 집단의 좋은 결과가 작은 위험 집단의 부진을 가릴 수 있다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

보완 B06 → 118쪽

빅데이터·AI 064회차 | 09-07 직접 문제

분류 평가와 불균형: 정밀도·재현율·F1 계산하기 · 과목 64/80회차 · 기록 묶음 13의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q19

TP24,FP6,FN16,TN154일 때 정밀도·재현율은?

1. 60%·80%

2. 89%·96.25%

3. 24%·16%

4. 80%·60%

내 선택·근거: _____

B09Q20

1,000건 중 양성 10건을 전부 음성으로 예측했다. 옳은 설명은?

1. 정확도 99%이므로 양성 재현율도 99%

2. 정밀도는 반드시 100%

3. 정확도 99%지만 양성 재현율 0이고 정밀도는 분모 0 상태다.

4. FN은 0건

내 선택·근거: _____

B09Q21

FP 비용 1,FN 비용 10이다. A는 FP20/FN5,B는 FP5/FN12라면 총비용은?

1. A25,B17

2. A200,B50

3. A70,B125

4. A125,B70

내 선택·근거: _____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 065회차 | 09-07 해설·재현

분류 평가와 불균형: 정밀도·재현율·F1 계산하기 · 과목 65/80회차 · 기록 묶음 13의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

먼저 직접 푼 뒤 확인합니다.

B09Q19

정답: 4번

정밀도24/(24+6)=80%,재현율24/(24+16)=60%다. 정확도와 특이도는 분모가 다르다.

B09Q20

정답: 3번

TP=0,FN=10,TN=990,FP=0이다. 정확도 990/1000=99%,재현율 0/10=0,정밀도 0/0이므로 정의와 도구 처리를 확인한다.

B09Q21

정답: 3번

A=20×1+5×10=70,B=5×1+12×10=125다. 주어진 가상 비용에서만 A가 유리하다고 해석한다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 066회차 | 09-07 원리 I

분류 평가와 불균형: 정밀도·재현율·F1 계산하기 · 과목 66/80회차 · 기록 묶음 14의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

강화 손풀이: 임계값과 오류 비용을 표로 동시에 계산한다

다음 가상 여섯 사례에서 점수 이상이면 양성으로 예측한다. 점수는 위험 정도를 정렬하는 값이며 확률 보정이 되었다고 가정하지 않는다.

점수	실제
0.9	양성
0.8	음성
0.7	양성
0.4	음성
0.3	양성
0.1	음성

1단계 - 임계값 0.7. 위 세 사례를 양성으로 예측한다. TP=2, FP=1, FN=1, TN=2다. 정밀도=2/3, 재현율=2/3, F1=2/3, 정확도=4/6이다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 067회차 | 09-07 원리ㅍ

분류 평가와 불균형: 정밀도·재현율·F1 계산하기 · 과목 67/80회차 · 기록 묶음 14의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

2단계 - 임계값 0.3. 위 다섯 사례를 양성으로 예측한다. TP=3, FP=2, FN=0, TN=1이다. 정밀도=3/5, 재현율=1, F1=2TP/(2TP+FP+FN)=6/8=0.75다. 정확도는 여전히 4/6이다. 같은 정확도가 같은 오류 구성이나 같은 비용을 뜻하지 않는다.

3단계 - 가상 비용. FP 한 건 비용은 2, FN 한 건 비용은 8이며 다른 비용은 없다고 정한다. 0.7은 1×2+1×8=10, 0.3은 2×2+0×8=4다. 두 후보만 비교할 때 0.3이 비용이 낮다. 모든 가능한 임계값 중 최적이라고 주장하려면 나머지 후보도 검토해야 한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 068회차 | 09-07 예제·적용

분류 평가와 불균형: 정밀도·재현율·F1 계산하기 · 과목 68/80회차 · 기록 묶음 14의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

반례. 고정된 같은 사례에서 임계값을 낮추면 예측 양성 집합은 커져 재현율은 줄어들지 않는다. 그러나 정밀도는 반드시 낮아지는 것이 아니다. 기존 양성 예측이 TP=1, FP=1이고 새로 포함한 사례가 양성 2개이면 정밀도는 1/2에서 3/4로 오른다. 데이터의 새 포함 집합을 확인한다. 임계값은 검증 자료로 선택하고 최종 시험 성능과 운영 오류 비용을 별도로 기록한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 069회차 | 09-07 직접 문제

분류 평가와 불균형: 정밀도·재현율·F1 계산하기 · 과목 69/80회차 · 기록 묶음 14의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이·서술형 작성
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개와 서술형 1개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q43

점수/실제는 0.9/양성,0.8/음성,0.7/양성,0.4/음성,0.3/양성,0.1/음성이다. 점수≥0.7이면 양성이다. 정밀도·재현율·F1은?

1. 1/3, 2/3, 1/2

2. 2/3, 1, 0.8

3. 모두 2/3

4. 모두 1

내 선택·근거: _____

B09Q44

점수/실제는 0.9/양성, 0.8/음성, 0.7/양성, 0.4/음성, 0.3/양성, 0.1/음성이다. 점수≥임계값이면 양성이다. FP비용 2·FN비용 8이고 다른 비용은 없으며 후보는 0.7·0.3뿐이다. 옳은 선택은?

1. 0.7의 비용2가 0.3의 비용4보다 낮다.

2. 정확도가 같으므로 비용도 반드시 같다.

3. 0.3의 비용4가 0.7의 비용10보다 낮다.

4. 0.3은 모든 가능한 임계값 중 최적임이 이 비교만으로 증명된다.

내 선택·근거: _____

B09Q45

점수/실제는 0.9/양성, 0.8/음성, 0.7/양성, 0.4/음성, 0.3/양성, 0.1/음성이다. 점수≥0.3을 양성으로 예측할 때 F1과 정확도는?

1. 0.6, 1

2. 1, 0.75

3. 2/3, 0.75

4. 0.75, 2/3

내 선택·근거: _____

W09Q07

점수/실제=[0.9/양성,0.8/음성,0.7/양성,0.4/음성,0.3/양성,0.1/음성]이다. 점수≥임계값이면 양성이다. 후보 0.7·0.3의 혼동행렬과 F1을 구하고 FP비용 2·FN비용 8의 합을 비교하라.

조건·원리·중간 과정·결론 순서로 먼저 답안을 작성합니다.

내 답안: _____

_____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 070회차 | 09-07 해설·재현

분류 평가와 불균형: 정밀도·재현율·F1 계산하기 · 과목 70/80회차 · 기록 묶음 14의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

서술형 모범답안과 자가 채점 기준

B09Q43

정답: 3번

정답 근거: TP2, FP1, FN1, TN2로 정밀도2/3, 재현율2/3, F1=4/(4+1+1)=2/3이다.

「모두 1」- 실제 음성 0.8을 양성으로 예측하고 실제 양성 0.3을 놓쳐 오류가 있다.

「1/3, 2/3, 1/2」- 정밀도의 분자는 TP2이고 F1도 2/3으로 제시값과 다르다.

「2/3, 1, 0.8」- 재현율1과 F1 0.8은 FN을 누락한 계산이다.

B09Q44

정답: 3번

정답 근거: 0.7은 FP1·FN1이라 2+8=10, 0.3은 FP2·FN0이라 4다. 두 후보 안에서는 0.3을 고른다.

「0.7의 비용2가 0.3의 비용4보다 낮다.」- 0.7에서 놓친 양성 한 건의 비용8을 빠뜨렸다.

「정확도가 같으므로 비용도 반드시 같다.」- 정확도는 두 유형의 오류를 같은 한 건으로 세지만 여기서는 비용 가중치가 다르다.

「0.3은 모든 가능한 임계값 중 최적임이 이 비교만으로 증명된다.」- 후보 둘만 비교했으므로 다른 임계값에 대한 최적성은 검사하지 않았다.

B09Q45

정답: 4번

정답 근거: TP3 FP2 FN0 TN1이다. F1=6/(6+2)=0.75, 정확도=(3+1)/6=2/3이다.

「0.6, 1」 - 0.6은 정밀도이고 음성 두 건을 양성으로 예측했으므로 정확도1이 아니다.

「1, 0.75」 - 1은 재현율이며 F1은 FP2 때문에 1이 아니다. 정확도도0.75가 아니다.

「2/3, 0.75」 - 2/3은 임계값0.7의 F1이며 정확도0.75도 여섯 사례의 정답4건과 맞지 않는다.

W09Q07

점수/실제=[0.9/양성,0.8/음성,0.7/양성,0.4/음성,0.3/양성,0.1/음성]이다. 점수≥임계값이면 양성이다. 후보 0.7·0.3의 혼동행렬과 F1을 구하고 FP비용 2·FN비용 8의 합을 비교하라.

모범답안

0.7은TP 2·FP 1·FN 1·TN 2, F1=4/(4+1+1)=2/3, 비용=1×2+1×8=10이다. 0.3은TP 3·FP 2·FN 0·TN 1, F1=6/(6+2)=0.75, 비용=2×2=4다. 두 후보만 비교하면 0.3의 비용이 낮다. 정확도는 둘 다 4/6이지만 비용과 F1은 다르다. 이 비교로 나머지 모든 임계값까지 최적이라고 증명한 것은 아니다.

10점 자가 채점 기준

- 4점: 임계값별 혼동행렬을 각 2점으로 채점한다. 각 행렬에서 한 값 오류는 1점, 둘 이상 오류는 0점.
- 3점: F1 두 값에 각 1점, 두 정확도 4/6의 일치 1점을 준다.
- 3점: 비용 10·4와 0.3 선택을 2점, 두 후보 범위의 결론이라는 한계를 1점으로 설명한다.

점수는 학습용 자가 채점이며 실제 시험 배점 재현이 아닙니다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 071회차 | 09-08 원리 I

군집·차원축소·거버넌스와 IT 시사 학습법 · 과목 71/80회차 · 기록 묶음 15의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

군집과 거리

군집은 정답 라벨 없이 비슷한 자료를 묶는 비지도학습이다. k-means는 정해진 k개 중심을 기준으로 자료를 배정하고 중심을 갱신하는 대표적인 접근이다. 초기 중심·거리·스케일·이상치에 영향을 받으며 모든 형태의 군집을 잘 찾는 것은 아니다. 군집 번호 0·1·2에 원래의 의미 있는 순서가 있는 것은 아니다.

유클리드 거리는 두 좌표 차이 제곱 합의 제곱근이다. A=(0,0),B=(3,4)의 거리는 5다. C=(0,2)와의 거리는 2다. 키와 연봉을 그대로 거리로 계산하면 숫자 단위가 큰 연봉이 지배할 수 있어 스케일을 검토한다. 코사인 유사도는 두 벡터 방향의 유사성을 보며 벡터 크기의 영향과는 다르게 동작한다. 영벡터에서는 정의 조건을 확인한다.

단계별 k-means 예제

1차원 자료 1,2,8,9에 초기 중심 1·9를 둔다. 가까운 중심으로 배정하면 첫 군집은 1·2,둘째는 8·9다. 새 중심은 (1+2)/2=1.5와 (8+9)/2=8.5다. 다음 배정도 같으면 이 예제에서는 중심이 안정된다. 이것이 어떤 초기값에서도 전역 최적을 반드시 찾는다는 증명은 아니다.

PCA의 큰 그림

PCA는 데이터의 큰 분산을 설명하는 직교 방향을 찾아 낮은 차원으로 표현하는 대표적인 선형 차원축소 기법이다. 군집과는 목적이 다르다. 원래 특징을 일부 골라 남기는 특징 선택과, 특징들의 선형 결합을 만드는 차원축소도 구별한다. 첫 주성분은 가장 큰 분산 방향을 설명하고 다음 성분은 이전과 직교하면서 남은 분산을 설명한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

보완 B08 → 120쪽

빅데이터·AI 072회차 | 09-08 원리ㅍ

군집·차원축소·거버넌스와 IT 시사 학습법 · 과목 72/80회차 · 기록 묶음 15의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

큰 분산이 예측에 가장 중요한 정보라는 보장은 없다. 단위가 다른 입력이면 스케일을 고려하며 PCA도 학습 부분에서 맞춘다. 민감한 정보가 낮은 차원으로 바뀌었다고 익명성이 자동으로 생기는 것은 아니다.

총 분산이 100이고 성분별 설명 분산이 60,25,15라면 첫 두 성분의 누적 설명 비율은 85%다. 목표가 90%라면 두 성분만으로는 부족하다. 이 숫자는 설명 분산이며 분류 정확도 85%라는 뜻이 아니다.

데이터 거버넌스와 모델 운영

거버넌스는 소유·책임·정의·품질·권한·계보·보관 등을 관리한다. 메타데이터는 자료의 의미와 생성·변환 정보를 설명한다. 데이터 품질에서는 정확성·완전성·일관성·적시성·유일성 등을 검토할 수 있다. 항목별 측정 기준이 필요하며 "자료가 많으니 품질이 좋다"는 주장은 틀리다.

운영에서 입력 분포가 달라지는 데이터 드리프트와 입력-정답 관계가 달라지는 개념 드리프트를 구분할 수 있다. 모델·자료·특징·설정 버전을 기록하고 성능·오류·편향을 모니터링한다. 설명 가능성·공정성·개인정보·사람의 검토 등은 업무 요구에 맞게 설계한다. 자동 점수가 곧 최종 법적·업무적 판단이라는 뜻은 아니다.

IT 시사 공부법

IBK IT의 시사 준비는 매일 기사 제목을 많이 외우는 것보다 확인 가능한 원문을 짧게 정리하는 방식이 유용하다. 한국은행·금융위원회·금융감독원·개인정보보호위원회·NIST 등의 공식 발표에서 발표일, 실제 시행일, 기존 개념, 변경 사항, IT 영향, 확인이 필요한 점을 기록한다. 공식 발표와 실제 적용 시점을 구분한다. 특정 올해 사건을 확인 없이 교재에 사실로 만들어 넣지 않는다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 073회차 | 09-08 예제·적용

군집·차원축소·거버넌스와 IT 시사 학습법 · 과목 73/80회차 · 기록 묶음 15의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

한 주에 두 주제만 골라 "클라우드 장애와 복구", "AI 데이터·보안", "디지털 인증" 같은 전산 개념과 연결하자. 뉴스는 공고 기준일과 시험 시점에 맞춰 갱신하며 기관별 실제 출제 빈도는 공식 안내가 없으면 추정이라고 표시한다.

자가 연습과 완료 기준

거래 군집은 행동 패턴 탐색이고 위험 여부 정답을 학습하는 분류와 다르다. PCA 누적 85%는 차원 정보의 요약이고 정확도가 아니다. 거리·중심·분산 비율을 계산하고, 데이터 품질·누수·권한·운영 감시를 함께 설명하면 이 교재의 기초를 통과한다.

응용 계산: 중심 거리와 군집 오차

1,2,8,9를 중심 1.5·8.5에 배정하면 각 제곱 거리는 0.25다. 군집 안의 제곱 거리 합은 1이다. 모든 값을 중심 5에 모으면 제곱 거리 합은 16+9+9+16=50이다. 군집 수를 늘리면 이 합은 줄어들 수 있지만 군집 수를 무조건 최대로 고르는 것이 업무에 좋다는 뜻은 아니다.

k-means의 k와 k-NN의 k는 다르다. 전자는 군집 중심 개수,후자는 예측에서 참고하는 이웃 개수다. PCA 성분 수와도 다르다. 같은 기호를 쓴다는 이유로 역할을 혼동하지 않는다. 보고서에는 모델 이름·설정·자료 기간·특징·평가 방식을 함께 적자.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 074회차 | 09-08 직접 문제

군집·차원축소·거버넌스와 IT 시사 학습법 · 과목 74/80회차 · 기록 묶음 15의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q22

1차원 값 1,2,8,9가 군집1={1,2},군집2={8,9}로 배정될 때 갱신 중심은?

1. 1과9

2. 2와8

3. 1.5와8.5

4. 5와5

내 선택·근거: _____

B09Q23

PCA 성분별 설명 분산 60,25,15이고 전체 100일 때 첫 두 성분 누적 비율은?

1. 60%

2. 75%

3. 85%

4. 100%

내 선택·근거: _____

B09Q24

IBK IT 시사 학습의 적절한 기록 방법은?

1. 연도 없는 제목만 암기

2. 발표일을 모두 시행일로 취급

3. 확인 없는 올해 사건을 사실로 추가

4. 공식 원문의 발표일·시행일·변경 내용·전산 개념과 영향을 구분해 기록

내 선택·근거: _____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 075회차 | 09-08 해설·재현

군집·차원축소·거버넌스와 IT 시사 학습법 · 과목 75/80회차 · 기록 묶음 15의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

먼저 직접 푼 뒤 확인합니다.

B09Q22

정답: 3번

k-means의 각 중심은 배정된 값의 평균이다. (1+2)/2=1.5,(8+9)/2=8.5다. 초기 중심과 혼동하지 않는다.

B09Q23

정답: 3번

(60+25)/100=85%다. 설명 분산 비율이며 분류 정확도 85%라는 뜻은 아니다. 90% 목표면 세 번째 성분도 검토한다.

B09Q24

정답: 4번

시점과 공식 근거를 분리해야 한다. 보도 시점과 실제 적용 시점이 다를 수 있으며 확인되지 않은 사실은 만들지 않는다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

빅데이터·AI 076회차 | 09-08 원리 I

군집·차원축소·거버넌스와 IT 시사 학습법 · 과목 76/80회차 · 기록 묶음 16의1/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 앞부분 읽기·용어·조건 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

강화 손풀이: 군집의 거리와 PCA의 분산은 목표를 자동으로 해결하지 않는다

군집 한 번 갱신. 가상 1차원 점 [0, 2, 8, 10]과 초기 중심 2, 8을 사용한다. 더 가까운 중심에 배정하면 [0, 2]와 [8, 10]이다. 각 평균으로 중심을 갱신하면 1, 9다. 갱신한 중심에서 제곱거리 합 SSE는 (0-1)^2+(2-1)^2+(8-9)^2+(10-9)^2=4다. 이 예시에는 거리 동률이 없으며 입력 단위와 특징 스케일은 고정한다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 077회차 | 09-08 원리ㅍ

군집·차원축소·거버넌스와 IT 시사 학습법 · 과목 77/80회차 · 기록 묶음 16의2/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	본문 가운데 부분 읽기·차이·경계 설명
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

PCA 손계산. 어떤 전처리를 고정한 뒤 공분산 행렬의 고유값이 9, 3, 2라고 가정한다. 전체 분산은 14, 첫 성분의 비중은 9/14, 앞 두 성분 누적은 12/14=6/7 약 85.71%다. 누적 90% 이상이라는 가상 기준에는 세 성분 모두 필요하다. 9와 3만 더해 12라고 보고 이를 12%나 90%로 읽으면 안 된다.

반례. 분산이 큰 특징이 예측 목표에 유용하다는 보장은 없다. 측정 단위가 큰 무관한 특징이 PCA의 주요 방향을 차지할 수도 있다. 앞 성분의 분산 보존과 분류 정답률을 같은 지표로 취급하지 않는다. 군집 번호에도 승인/거절 같은 의미가 자동으로 부여되지 않는다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 078회차 | 09-08 예제·적용

군집·차원축소·거버넌스와 IT 시사 학습법 · 과목 78/80회차 · 기록 묶음 16의3/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	남은 본문·예제의 중간 상태 손추적
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

운영 실무 조건. 모델 성능이 갑자기 떨어졌을 때 원천 자료·기간·특징 순서·전처리 버전·모델 버전·평가 대상·라벨 수집 지연을 먼저 함께 확인한다. 예를 들어 열 이름은 같지만 단위가 원에서 천 원으로 바뀌면 같은 모델에도 입력이 달라진다. 계보와 버전을 기록하고 원인을 재현한 뒤 수정한다. 이 내용은 보편적인 학습 보강이며 기관의 공식 IT/디지털 출제범위를 새로 동일시하는 근거가 아니다.

오늘 완료 기준

오늘 실제 읽은 절의 용어·조건을 자기 말로 설명하고 해당 예제의 중간 상태를 적습니다. 아직 읽지 못한 절은 다음 시작점으로 남깁니다.

빅데이터·AI 079회차 | 09-08 직접 문제

군집·차원축소·거버넌스와 IT 시사 학습법 · 과목 79/80회차 · 기록 묶음 16의4/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	지정 문제 독립 풀이·서술형 작성
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

오늘 지정 범위: 객관식 3개와 서술형 1개.

정답 페이지를 펼치기 전에 내 선택·근거와 중간 계산을 적습니다.

B09Q46

점 [0,2,8,10]을 초기 중심 2,8에 가까운 쪽으로 배정 후 평균 중심 1,9로 갱신했다. 갱신 중심에 대한 SSE는?

1. 4

2. 0

3. 2

4. 20

내 선택·근거: _____

B09Q47

고정한 전처리 뒤 PCA 고유값은 9,3,2다. 앞 두 성분 누적 비중과 누적 90% 이상에 필요한 최소 성분 수는?

1. 6/7 약 85.71%, 3개

2. 90%, 2개

3. 9/14 약 64.29%, 1개

4. 12%, 2개

내 선택·근거: _____

B09Q48

배포 후 성능이 갑자기 떨어졌다. 특징 이름은 같지만 입력 금액 단위가 원에서 천 원으로 바뀐 기록이 있다. 적절한 대응은?

1. 열 이름이 같으면 값의 의미도 같으므로 단위 변경은 무시한다.

2. 입력 단위·전처리·모델 버전·평가 기간을 연결해 재현하고 원인을 확인한다.

3. PCA 분산 보존률이 높으면 입력 오류가 있어도 분류 성능은 보장된다.

4. 군집 번호가 있으면 승인/거절 의미가 자동으로 정해진다.

내 선택·근거: _____

W09Q08

점[0,2,8,10]과 초기 중심 2·8의 한 번 군집 갱신 뒤 중심과 SSE를 계산하라. PCA 고유값 9·3·2에서 90% 기준의 최소 성분 수를 계산하고 예측 성능에 대한 한계를 적어라.

조건·원리·중간 과정·결론 순서로 먼저 답안을 작성합니다.

내 답안: _____

_____

오늘 완료 기준

내 선택과 조건·근거를 먼저 남깁니다. 정답은 바로 다음 별도30분 회차에서 확인합니다. 서술형이 있으면 초안·식·결론을 먼저 적습니다.

빅데이터·AI 080회차 | 09-08 해설·재현

군집·차원축소·거버넌스와 IT 시사 학습법 · 과목 80/80회차 · 기록 묶음 16의5/5단계

분	할 일
3	앞선 개념 또는 첫 오류 한 가지를 답 없이 회상
25	분리 해설 비교·자가 채점·답 없는 재풀이
2	실제 공부 분·첫 오류·다음 시작점 기록

30분에 멈춥니다. 지정 내용이 남으면 다음 학습일에 같은 회차를 이어갑니다. 아래 자료의 쪽수가 하루에 반드시 끝낼 분량을 뜻하지 않습니다.

오늘 자료

서술형 모범답안과 자가 채점 기준

B09Q46

정답: 1번

정답 근거: 네 점이 각각 중심에서 거리1이므로 제곱거리 합은1+1+1+1=4다.

「2」 - 군집 수2와 제곱거리 합4를 혼동했거나 군집 하나만 계산했다.

「20」 - 초기 중심의 SSE8도 아니며 갱신 중심의 네 제곱거리 계산과 맞지 않는다.

「0」 - 각 점이 중심과 일치하지 않아 오차가 남아 있다.

B09Q47

정답: 1번

정답 근거: 전체14에서 앞 두 성분12를 보존해12/14=6/7이다. 두 성분은90% 미달이므로 세 성분이 필요하다.

「12%, 2개」 - 분산 합12는 비율12%가 아니다. 분모14를 사용해야 한다.

「90%, 2개」 - 12/14는90%보다 작다.

「9/14 약 64.29%, 1개」 - 9/14는 첫 성분 하나의 비중이며90%에도 미달이다.

B09Q48

정답: 2번

정답 근거: 자료 계약의 단위 변화가 값 크기를 바꿀 수 있다. 버전과 계보를 연결해 재현하고 평가 조건을 확인한다.

「열 이름이 같으면 값의 의미도 같으므로 단위 변경은 무시한다.」 - 같은 이름에 다른 단위가 적용되면 모델이 해석하는 수치의 의미가 달라질 수 있다.

「PCA 분산 보존률이 높으면 입력 오류가 있어도 분류 성능은 보장된다.」 - 분산 보존률은 목표 예측 성능이나 입력 계약의 정상 여부를 보장하지 않는다.

「군집 번호가 있으면 승인/거절 의미가 자동으로 정해진다.」 - 군집 번호는 그룹 식별이며 업무 결정 의미는 별도로 정해야 한다.

W09Q08

점[0,2,8,10]과 초기 중심 2·8의 한 번 군집 갱신 뒤 중심과 SSE를 계산하라. PCA 고유값 9·3·2에서 90% 기준의 최소 성분 수를 계산하고 예측 성능에 대한 한계를 적어라.

모범답안

군집은[0,2]와[8,10], 새 중심은 1·9, SSE는 1+1+1+1=4다. PCA 전체 분산 14에서 첫 두 성분은 12/14 약 85.71%로 90% 미달이므로 세 성분이 필요하다. 큰 분산을 보존했다고 목표와 관련된 특징을 보존하거나 분류 성능을 보장하지 않는다. 군집 번호에도 승인/거절 의미는 자동으로 생기지 않는다. 입력 단위·전처리·모델·평가 조건을 기록해 의미와 성능을 확인한다.

10점 자가 채점 기준

- 4점: 배정된 두 군집 1점, 새 중심 1·9를 1점, SSE4의 제곱거리 계산 2점을 준다.
- 3점: 전체 14와 두 성분 12/14를 2점, 최소 3개를 1점으로 계산한다.
- 3점: 분산 보존과 예측 성능의 차이 2점, 군집 의미 또는 운영 버전 계약의 한계 1점을 설명한다.

점수는 학습용 자가 채점이며 실제 시험 배점 재현이 아닙니다.

오늘 완료 기준

첫 오류의 조건을 적고 답을 닫아 재현합니다. 서술형은 모범답안과10점 자가 채점 근거도 남깁니다. 남은 부분이 있으면 같은 회차로 이어갑니다.

근거·범위·검증 상태

현재 GI 장별 교재와 과목별 문제·해설·서술형을 바탕으로 구성했습니다. 기관 공고 범위의 기존 확인 기준은2026-10-04, 이번 PDF 구성일은2026-10-11입니다. 다음 지원 시 새 공식 안내를 다시 확인합니다.

- IBK 채용 FAQ - IT와 디지털 출제영역 구분
- 기술보증기금 2026 상세 출제범위 - 빅데이터 별도 미명시
- NIST Big Data Definitions - 확장성과 데이터 특성
- Apache Hadoop MapReduce 공식 Tutorial
- Google Machine Learning Crash Course
- Google ML Classification Metrics
- scikit-learn Common Pitfalls - 분할과 누수
- scikit-learn StandardScaler
- scikit-learn Clustering
- scikit-learn PCA
- 한국은행 - IT·금융 시사 원문 확인
- 금융위원회 - 금융 정책 원문 확인
- 금융감독원 - 공식 보도자료 확인

핵심 보완 찾아보기

원래 회차와 문제 순서는 그대로 따라갑니다. 아래 보완 자료는 해당 개념이 헷갈리는 날의 학습 25분 안에서 본문과 바꾸어 읽습니다. 추가 과제로 더하지 않습니다.

노란색은 정의·공식·판단 조건입니다. 「헷갈리는 지점」은 혼동하기 쉬운 경계를 설명합니다. 강조 개수는 출제 빈도나 배점을 뜻하지 않습니다.

B01. 평균을 합칠 때는 표본 수를 함께 보관한다

002~003회차 | 통계·분모 | 본문 8쪽 → 보완 자료의 같은 번호

B02. MapReduce 평균은 합계·개수 쌍으로 결합한다

022~023회차 | MapReduce | 본문 34쪽 → 보완 자료의 같은 번호

B03. 전처리도 학습되며 테스트에는 적용만 한다

031~033회차 | 전처리 | 본문 46쪽 → 보완 자료의 같은 번호

B04. R^2는 음수가 될 수 있고 정확도가 아니다

041~043회차 | 회귀 손실 | 본문 59쪽 → 보완 자료의 같은 번호

B05. 시간·고객·라벨 확보 시점을 함께 분할한다

051~053회차 | 누수·교차검증 | 본문 72쪽 → 보완 자료의 같은 번호

B06. Macro-F1은 Macro 정밀도·재현율의 조화평균과 다르다

063~066회차 | 평가 평균 방식 | 본문 87쪽 → 보완 자료의 같은 번호

B07. 임계값과 순위 지표를 혼동하지 않는다

062~063회차 | 임계값·ROC | 본문 86쪽 → 보완 자료의 같은 번호

B08. 군집 거리·차원축소는 단위와 목표에 의존한다

071~073회차 | 군집·PCA | 본문 98쪽 → 보완 자료의 같은 번호

정답·해설은 보완 문제 뒤의 별도 절에서 확인합니다. PDF 책갈피의 「핵심 보완」에서 각 주제로 바로 이동할 수 있습니다.

B01. 평균을 합칠 때는 표본 수를 함께 보관한다

연결: 002~003회차 | 통계·분모 | 본문 8쪽

전체 평균은 집단별 평균의 단순평균이 아니라 총합/총개수다.

원리와 판단 조건

A집단 평균을 a,개수를 m, B집단 평균을 b,개수를 n이라 하면 합친 평균은 (ma+nb)/(m+n)이다.

표본 수가 다르면 평균만 저장해 놓고 정확한 전체 평균을 복원할 수 없다. 분산 역시 전체 평균이 결정된 후 편차 제곱을 기준으로 계산한다.

결측값을 제외했다면 평균의 유효 관측 개수를 가중치로 써야 한다. 전체 행 수와 알려진 값 개수는 다를 수 있다.

적용·손풀이

A={0,10}은 평균5·개수2, B={100}은 평균100·개수1이다. 평균의 평균52.5는 틀리고, 전체 평균은 (5×2+100×1)/3=110/3 36.667이다. 값10,10,NULL은 알려진 값 평균10이지만 NULL을0으로 정의하면20/3이다.

헷갈리는 지점

두 집단 평균이 주어졌다는 이유만으로 평균을 반씩 더하지 않는다.

직접 확인

전체 합120, 유효 관측4개인 묶음과 합80, 유효 관측1개를 합치면?

참고: SQLite 평균·합계·개수 정의 (www.sqlite.org)

B02. MapReduce 평균은 합계·개수 쌍으로 결합한다

연결: 022~023회차 | MapReduce | 본문 34쪽

분산 중간 집계는 묶는 순서가 달라도 의미가 유지되는 형태로 설계한다.

원리와 판단 조건

단어 개수의 합처럼 결합 가능한 통계는 로컬 집계 후 전체로 합칠 수 있다. 평균 하나만 중간값으로 내보내면 묶음 크기를 잃는다.

평균을 위해 (sum,count)를 중간 결과로 보낸다. 두 쌍의 결합은 (s1+s2,c1+c2)이고 마지막에 s/c를 계산한다.

Combiner는 항상 실행된다는 전제로 정확성을 설계하지 않는다. 최적화가 없어도 Reducer가 같은 올바른 결과를 내야 한다.

적용·손풀이

노드A의10,20은(30,2), 노드B의90은(90,1)이다. 결합하면(120,3), 평균40이다. 노드 평균15와90을 단순평균한52.5는 잘못된 결과다. Mapper가 같은 키에 보낸 쌍은 합계를 합쳐도 원소 개수가 보존된다.

헷갈리는 지점

결과 자료형이 숫자라는 이유로 어떤 집계에도 같은 Combiner를 붙이지 않는다.

직접 확인

로컬값(20,2),(70,1),(0,0)을 합친 평균은?

참고: Apache Hadoop MapReduce Tutorial (hadoop.apache.org)

B03. 전처리도 학습되며 테스트에는 적용만 한다

연결: 031~033회차 | 전처리 | 본문 46쪽

분할 후 학습 부분으로 fit하고 검증·시험에는 같은 변환을 적용한다.

원리와 판단 조건

평균 대치·표준화·특징 선택·PCA도 자료에서 정보를 얻는다. 모델 학습 전에 수행했다는 이유로 누수에서 자유롭지 않다.

훈련에서 범주를 A,B로 학습했다면 운영에서 C가 나올 때 오류 처리 또는 미지 범주 규칙을 정한다. OneHotEncoder의 handle_unknown 설정처럼 엔진의 동작을 확인한다.

교차검증에서는 각 fold의 훈련 부분 안에서 전처리까지 다시 학습하도록 Pipeline 등으로 묶는다.

적용·손풀이

훈련값0,2의 평균은1이다. 시험값100을 포함해 평균34로 표준화 중심을 정하면 시험 정보가 이미 변환에 들어갔다. 올바른 중심은1이며 시험값에도 훈련 중심1을 사용한다.

헷갈리는 지점

시험세트에는 fit_transform을 새로 수행해 별도의 기준을 만들지 않는다.

직접 확인

결측 대치용 중앙값을 전체 자료에서 먼저 구한 뒤 train/test 분할하면?

참고: scikit-learn 데이터 누수 방지 (scikit-learn.org)

B04. R^2는 음수가 될 수 있고 정확도가 아니다

연결: 041~043회차 | 회귀 손실 | 본문 59쪽

R^2=1-SSE/SST이며 평균 예측보다 나쁘면 음수다.

원리와 판단 조건

SSE는 실제값과 예측값 차이의 제곱합, SST는 실제값과 그 평균 차이의 제곱합이다. 실제값이 비상수일 때 정의를 적용한다.

MAE는 원래 값의 단위, MSE는 단위의 제곱, RMSE는 원래 단위다. 지표 이름만 보지 말고 업무상 해석과 큰 오류의 영향을 비교한다.

정답이 모두 같은 상수이면 R^2 분모가0이다. 라이브러리가 예외를 어떻게 처리하는지 확인하며 일반 비상수 예제와 분리한다.

적용·손풀이

실제값[1,2,3],예측값[2,2,2]면 SSE=2,SST=2라 R^2=0이다. 예측[4,4,4]면 SSE=14라 R^2=1-14/2=-6이다. MAE=(3+2+1)/3=2,MSE=14/3이다.

헷갈리는 지점

R^2를0~1 범위의 분류 정확도 또는 "맞힌 비율"로 해석하지 않는다.

직접 확인

실제값[1,3],예측값[2,2]의 R^2와 MAE는?

참고: scikit-learn R^2 score (scikit-learn.org)

B05. 시간·고객·라벨 확보 시점을 함께 분할한다

연결: 051~053회차 | 누수·교차검증 | 본문 72쪽

미래 예측이라면 미래 정보가 과거 훈련 판단에 들어가지 않아야 한다.

원리와 판단 조건

매달 신청 시점으로부터3개월 내 부실을 예측한다면 라벨 확정에3개월이 필요하다. 6월 평가를 위한 훈련 자료는 6월 이전에 라벨이 실제 확보된 범위여야 한다.

시간순 분할을 해도 라벨 관측 기간이 시험 기간과 겹치면 누수가 생길 수 있다. 문제의 예측 시점과 관측 창에 맞춰 gap을 검토한다.

새 고객 예측이 목표면 같은 고객의 이력이 양쪽에 걸리지 않는지도 확인한다. 무조건 한 분할법이 모든 목표를 해결하지는 않는다.

적용·손풀이

1~5월 신청을 훈련으로,6월을 시험으로 나눴지만 5월 신청의8월 결과를 이미 훈련에 넣으면 "6월에 사용 가능했던 모형"을 재현하지 못한다. 사용 가능한 라벨 시점까지 훈련 범위를 제한한다.

헷갈리는 지점

train의 날짜가 test보다 빠르다는 조건 하나만 확인하고 라벨 생성 시점을 놓치지 않는다.

직접 확인

신청 다음날 확정되는 승인 결과를 신청 시점의 입력 특징으로 쓰면?

참고: scikit-learn TimeSeriesSplit (scikit-learn.org)

B06. Macro-F1은 Macro 정밀도·재현율의 조화평균과 다르다

연결: 063~066회차 | 평가 평균 방식 | 본문 87쪽

범주별 F1을 먼저 계산한 후 평균하는 순서를 지킨다.

원리와 판단 조건

Macro 평균은 각 범주의 지표를 같은 비중으로 평균한다. Weighted 평균은 범주 실제 표본 수인 support로 가중한다.

F1=2PR/(P+R)은 비선형이므로 "각 범주의 F1 평균"과 "평균 P,R의 F1"은 일반적으로 다르다.

분모가0인 경우도 별도로 정의한다. 라이브러리의 zero_division 옵션과 보고 정책을 확인하고 값을 숨기지 않는다.

적용·손풀이

A범주 P=1,R=0.5이면 F1=2/3, B범주 P=0.5,R=1이면 F1=2/3이다. Macro-F1은2/3 0.667이다.
Macro-P=Macro-R=0.75를 조화평균한0.75는 Macro-F1이 아니다.

헷갈리는 지점

Weighted-F1이 높다는 이유로 소수 범주 재현율도 좋다고 결론 내리지 않는다.

직접 확인

두 범주의 F1이0.8과0.2,지원 수가90과10이면 macro와 weighted F1은?

참고: scikit-learn 정밀도·재현율·F 점수 (scikit-learn.org)

B07. 임계값과 순위 지표를 혼동하지 않는다

연결: 062~063회차 | 임계값·ROC | 본문 86쪽

같은 점수라도 임계값이 바뀌면 혼동행렬이 바뀐다.

원리와 판단 조건

고정된 점수에서 임계값을 낮추면 양성 집합이 커져 TP와 FP가 줄어들지는 않는다. 재현율은 감소하지 않지만 정밀도는 개별 표본에서 증가할 수도 있다.

AUC는 점수의 순위 판별을 요약한다. 특정 임계값의 정확도·비용·확률 보정과 동일한 값이 아니다.

최종 시험세트로 가장 좋은 임계값을 반복 선택하지 않는다. 임계값 결정도 모델 선택 과정에 속한다.

적용·손풀이

점수0.9의실제양성,0.8의실제음성,0.7의실제양성이 있다. 임계값0.8 이상이면 P=1/2,R=1/2다. 0.7 이상으로 낮추면 P=2/3,R=1이다. 이 표본에서는 정밀도도 높아진다.

헷갈리는 지점

"임계값을 낮추면 정밀도는 반드시 감소"를 항상 참인 수학 법칙으로 외우지 않는다.

직접 확인

같은 모형에서0.5 대신0.3 임계값을 썼다는 사실만으로 ROC-AUC도 달라지는가?

참고: scikit-learn 모델 평가 (scikit-learn.org)

B08. 군집 거리·차원축소는 단위와 목표에 의존한다

연결: 071~073회차 | 군집·PCA | 본문 98쪽

거리 기반 방법에서 단위 차이가 결과를 지배할 수 있다.

원리와 판단 조건

나이와 연소득을 원시 숫자 그대로 유클리드 거리로 비교하면 단위가 큰 소득의 영향이 압도적일 수 있다. 표준화가 필요한지 업무 의미와 함께 검토한다.

k-means의 군집 번호에는 정답 범주 의미가 자동으로 붙지 않는다. 중심 초기값·이상치·k 선택에 영향을 받는다.

PCA는 큰 분산 방향을 요약한다. 설명분산 비율은 목표변수 예측 정확도와 동일하지 않다.

적용·손풀이

기준(나이30,소득4000)에 대해 A(31,5000),B(40,4001)의 원시 제곱거리는 각각1,000,001과101이다. 소득 단위를 천 단위로 바꾸면 A는$1^2+1^2=2$,B는$10^2+0.001^2$ 100이 되어 가까운 대상이 바뀐다.

헷갈리는 지점

스케일 변경이 단순 표시 형식만 바뀐 것이므로 거리 결과도 같으리라고 생각하지 않는다.

직접 확인

PCA 첫 두 성분 설명분산이90%면 분류 정확도도90%인가?

참고: scikit-learn 군집화 (scikit-learn.org)

보완 문제 정답·해설

문제를 먼저 풀고 첫 오류를 확인합니다. 풀이를 닫은 뒤 같은 조건을 다시 설명할 수 있으면 다음 회차로 넘어갑니다.

B01. 평균을 합칠 때는 표본 수를 함께 보관한다

전체 평균은200/5=40이다. 두 평균30과80을 단순평균한55가 아니다.

B02. MapReduce 평균은 합계·개수 쌍으로 결합한다

총합90/개수3=30이다. 개수0인 묶음의 평균을 임의로0이라 두고 평균내지 않는다.

B03. 전처리도 학습되며 테스트에는 적용만 한다

검증·시험 정보가 대치 규칙에 들어갈 수 있다. 분할 후 훈련 중앙값을 구해 다른 세트에 그대로 적용한다.

B04. R^2는 음수가 될 수 있고 정확도가 아니다

평균2,SST=2,SSE=2이므로 R^2=0,MAE=1이다. 평균 기준보다 개선되지 않은 예측이다.

B05. 시간·고객·라벨 확보 시점을 함께 분할한다

예측 시점 이후 정보이므로 누수다. 실제 그 시점에 알 수 있었는지를 기준으로 특징을 판정한다.

B06. Macro-F1은 Macro 정밀도·재현율의 조화평균과 다르다

Macro=(0.8+0.2)/2=0.5,weighted=(90×0.8+10×0.2)/100=0.74다.

B07. 임계값과 순위 지표를 혼동하지 않는다

아니다. 같은 연속 점수의 ROC-AUC와 특정 임계값의 분류 결과는 별도다. 보고한 AUC가 어떤 입력으로 계산되었는지 확인한다.

B08. 군집 거리·차원축소는 단위와 목표에 의존한다

아니다. 입력 변동의90%를 설명한다는 의미다. 예측 성능은 별도 검증 자료와 목표 지표로 측정한다.